ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



Phạm Nhật Minh

NGHIÊN CỨU CẢI TIẾN MÔ HÌNH NGÔN NGỮ - THỊ GIÁC CHO BÀI TOÁN TRÍCH XUẤT THÔNG TIN CHÍNH TRÊN TÀI LIỆU

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY
Ngành: Công nghệ thông tin

HÀ NỘI - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



Phạm Nhật Minh

NGHIÊN CỨU CẢI TIẾN MÔ HÌNH NGÔN NGỮ - THỊ GIÁC CHO BÀI TOÁN TRÍCH XUẤT THÔNG TIN CHÍNH TRÊN TÀI LIỆU

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Công nghệ thông tin

Cán bộ hướng dẫn: TS. Phạm Thị Quỳnh Trang

HÀ NỘI - 2026

Tóm tắt

Trích xuất thông tin chính KIE (Key Information Extraction) từ các tài liệu giàu thị giác VRD (Visually Rich Documents) như biểu mẫu hành chính, hóa đơn thương mại và biên lai bán lẻ đóng vai trò nền tảng trong lĩnh vực Trí tuệ nhân tạo cho Tài liệu Document AI và Tự động hóa quy trình bằng robot RPA (Robotic Process Automation). Các mô hình Transformer đa phương thức tiền huấn luyện, tiêu biểu là LayoutLMv3, đã đạt được những bước tiến lớn nhờ kết hợp đồng thời văn bản, tọa độ bố cục hai chiều (2D) và đặc trưng hình ảnh thông qua cơ chế che mặt nạ hợp nhất. Tuy nhiên, kiến trúc gán nhãn chuỗi ở mức token tiêu chuẩn của LayoutLMv3 vẫn tồn tại ba hạn chế cốt lõi về mặt cấu trúc và ngữ cảnh: (1) sự phụ thuộc hoàn toàn vào tọa độ hộp giới hạn 2D tuyệt đối khiến mô hình phải tự suy luận ngầm định các cấu trúc phân cấp vĩ mô như dòng văn bản, khối cục bộ và cột dọc; (2) việc phân loại độc lập trên từng token thiếu sự trao đổi ngữ cảnh tường minh giữa các phân đoạn lân cận theo thứ tự đọc, dẫn tới hiện tượng trôi nhãn BIO trên các thực thể dài nhiều token; và (3) sự thiếu vắng ràng buộc ranh giới tường minh giữa các cặp token liên tiếp khiến mô hình dễ phân mảnh hoặc gộp sai các thực thể liền kề trên cùng một dòng.

Nhằm giải quyết đồng thời các thách thức trên mà không cần tiền huấn luyện lại từ đầu, khóa luận nghiên cứu và đề xuất khung kiến trúc cải tiến trên nền tảng LayoutLMv3 (triển khai trong lớp mô hình `LayoutLMv3For SegmentTokenClassification`) tích hợp ba thành phần bổ trợ lẫn nhau: (1) **Mã hóa vị trí phân cấp HPE (Hierarchical Position Encoding)** trích xuất chỉ số dòng, khối và cột bằng các thuật toán gom cụm hình học để nhúng trực tiếp cấu trúc bố cục vĩ mô vào biểu diễn đầu vào; (2) **Mô-đun ngữ cảnh phân đoạn SCM (Segment Context Module)** thực hiện gộp trung bình các token trong cùng phân đoạn, lan truyền ngữ cảnh liên phân đoạn qua bộ mã hóa Transformer nhẹ kết hợp cổng dư ReZero và nhúng đánh dấu token đầu phân đoạn (`is_first_`

`token_embedding`) nhằm duy trì tính nhất quán ngữ nghĩa đồng thời bảo toàn chuẩn gán nhãn BIO; và (3) **Hàm mất mát ranh giới nội dòng/thực thể** huấn luyện bộ phân loại nhị phân trên từng cặp token liên tiếp dựa trên định danh thực thể liên tục (`entity_ids`) để củng cố ranh giới chuyển tiếp thực thể. Thực nghiệm kiểm chứng nghiêm ngặt qua 3 hạt giống ngẫu nhiên $\{42, 123, 1993\}$ trên máy chủ GPU NVIDIA A100-SXM4-80GB với hai bộ dữ liệu chuẩn quốc tế FUNSD và CORD cho thấy mô hình đề xuất cải thiện vượt trội điểm F1 mức thực thể từ $89.92 \pm 0.85\%$ lên $91.58 \pm 0.16\%$ (+1.66%, giảm hơn 5 lần độ lệch chuẩn) trên tập FUNSD với biến thể `base`, đồng thời duy trì độ chính xác và tính ổn định cao trên tập dữ liệu biên lai CORD.

Từ khóa: Trích xuất thông tin chính KIE (Key Information Extraction), Tài liệu giàu thị giác VRD (Visually Rich Documents), LayoutLMv3, Mã hóa vị trí phân cấp HPE (Hierarchical Position Encoding), Mô-đun ngữ cảnh phân đoạn SCM (Segment Context Module), Hàm mất mát ranh giới, Gán nhãn chuỗi BIO.

Lời cảm ơn

Đầu tiên, em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến giảng viên hướng dẫn của em là TS. Phạm Thị Quỳnh Trang. Trong suốt khoảng thời gian thực hiện khóa luận tốt nghiệp cũng như trong quá trình học tập và nghiên cứu tại trường, cô đã luôn tận tình định hướng, chỉ bảo chuyên môn và tạo động lực giúp em hoàn thiện khóa luận này.

Tiếp theo, em xin gửi lời cảm ơn sâu sắc đến các thầy cô Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội. Nhờ sự giảng dạy tận tâm của các thầy cô trong suốt những năm học đại học, em đã được trang bị nền tảng kiến thức vững chắc và phương pháp tư duy khoa học quý báu cho hành trình nghiên cứu và sự nghiệp sau này.

Em cũng xin gửi lời cảm ơn đến các thầy cô trong Khoa Công nghệ Thông tin, Trường Đại học Công nghệ cùng các anh chị, các bạn nghiên cứu sinh và sinh viên trong nhóm nghiên cứu đã luôn nhiệt tình trao đổi, hỗ trợ tài nguyên tính toán và đóng góp nhiều ý kiến thiết thực trong quá trình thực nghiệm mô hình.

Cuối cùng, em xin gửi lời biết ơn sâu sắc nhất đến gia đình, bố mẹ và bạn bè – những người luôn ở bên cạnh động viên, sẻ chia và là điểm tựa vững chắc nhất giúp em vượt qua mọi khó khăn để hoàn thành tốt khóa luận tốt nghiệp.

Hà Nội, tháng 10 năm 2026

Sinh viên

Phạm Nhật Minh

Lời cam đoan

Tôi xin cam đoan các phương pháp cải tiến, mã nguồn thực nghiệm và kết quả phân tích được trình bày trong khóa luận này là do tôi thực hiện dưới sự hướng dẫn khoa học của TS. Phạm Thị Quỳnh Trang và PGS. TS. Lê Đức Trọng.

Trong khóa luận này, mọi tham khảo từ các công trình nghiên cứu đã công bố đều được trích dẫn đầy đủ và rõ ràng, không có sự sao chép trái phép tài liệu hay công trình của người khác. Nếu có bất kỳ sai phạm nào, tôi xin hoàn toàn chịu trách nhiệm theo quy định của Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội.

Sinh viên

Phạm Nhật Minh

Mục lục

Tóm tắt **ii**

Lời cảm ơn **iv**

Lời cam đoan **v**

Danh sách thuật ngữ **ix**

Mở đầu **1**

1 Giới thiệu **3**

1.1 Trí tuệ nhân tạo cho Tài liệu và Trích xuất thông tin chính KIE (Key Information Extraction) 3

1.2 Các vấn đề thách thức trong Trích xuất thông tin chính 4

1.2.1 Hạn chế của biểu diễn tọa độ phẳng hai chiều 4

1.2.2 Hiện tượng trôi nhãn BIO và xung đột độ mịn phân đoạn – token 5

1.2.3 Sự bất định tại ranh giới chuyển tiếp thực thể nội dòng . . 6

1.3 Các hướng tiếp cận chính trong bài toán KIE 6

1.3.1 Ba nhóm kiến trúc phổ biến cho hiểu tài liệu giàu thị giác . 6

1.3.2 Các chiến lược mô hình hóa cấu trúc ở giai đoạn tinh chỉnh 7

1.4 Bài toán đồ án 8

2 Các kỹ thuật liên quan **10**

2.1 Mô hình nền tảng đa phương thức LayoutLMv3 10

2.1.1 Biểu diễn nhúng văn bản và không gian hai chiều 10

2.1.2 Biểu diễn nhúng mảnh ảnh thị giác 12

2.1.3 Cơ chế tự chú ý nhận thức không gian và ổn định hóa CogView 12

2.1.4 Ba mục tiêu tiền huấn luyện hợp nhất của LayoutLMv3 . . 13
2.2 Các hướng nghiên cứu liên quan trong Document AI và KIE 13
2.2.1 Các mô hình Transformer nền tảng đa phương thức 14
2.2.2 Mô hình hóa cấu trúc hình học, đồ thị và thứ tự đọc 14
2.2.3 Các công trình cải tiến trên nền tảng LayoutLMv3 14
2.2.4 Mô hình sinh LLM so với mô hình phân biệt chuỗi trong KIE 14
2.2.5 Trích xuất quan hệ và thích ứng tham số trong học sâu . . . 15
2.3 Định hướng và mục tiêu nghiên cứu của khóa luận 15

3 Phương pháp đề xuất **18**
3.1 Mã hóa vị trí phân cấp HPE (Hierarchical Position Encoding) . . . 18
3.1.1 Gom cụm hình học xác định chỉ số Dòng, Khối và Cột . . . 18
3.1.2 Phép chiếu nhúng phân cấp có trọng số giảm chấn cột . . . 20
3.2 Mô-đun ngữ cảnh phân đoạn SCM (Segment Context Module) . . . 21
3.2.1 Khôi phục ranh giới phân đoạn và gộp trung bình 21
3.2.2 Trao đổi ngữ cảnh liên phân đoạn qua cổng dư ReZero và nhúng Token đầu 21
3.3 Hàm mất mát ranh giới nội dòng/thực thể 22
3.3.1 Thuật toán gán mã định danh thực thể liên tục (`compute_entity_ids`) 22
3.3.2 Mạng phân loại ranh giới cặp Token và hàm mất mát nhị phân 23
3.4 Quy trình huấn luyện tổng thể và tối ưu hóa tốc độ học phân biệt 24

4 Thực nghiệm và kết quả **26**
4.1 Môi trường thực nghiệm 26
4.2 Dữ liệu thực nghiệm 27
4.3 Chỉ số đánh giá 28
4.4 Cài đặt cấu hình 29
4.5 Kết quả thực nghiệm 30
4.5.1 Kết quả chi tiết theo từng hạt giống ngẫu nhiên trên máy chủ A100 30
4.5.2 So sánh với các phương pháp tiên tiến trên FUNSD và CORD 32
4.5.3 Nghiên cứu cắt giảm thành phần và tiến độ thực nghiệm . . 34
4.5.4 Phân tích lỗi mức thực thể và chi phí tính toán 34

Kết luận **38**

DANH SÁCH THUẬT NGỮ

Thuật ngữ	**Viết tắt**	**Diễn giải**
Key Information Extraction	KIE	Trích xuất thông tin chính từ tài liệu
Visually Rich Documents	VRDs	Tài liệu giàu thông tin thị giác và bố cục (biểu mẫu, hóa đơn, biên lai)
Document Artificial Intelligence	Document AI	Trí tuệ nhân tạo xử lý và hiểu tài liệu tự động
Optical Character Recognition	OCR	Nhận dạng ký tự quang học từ ảnh tài liệu
Hierarchical Position Encoding	HPE	Mã hóa vị trí phân cấp theo dòng, khối và cột
Segment Context Module	SCM	Mô-đun ngữ cảnh phân đoạn sử dụng gộp trung bình và Transformer liên phân đoạn
Late Token-Segment Fusion	LTSF	Cơ chế dung hợp trễ giữa biểu diễn mức phân đoạn và mức token
Intra-Line Boundary Loss	Boundary Loss	Hàm mất mát ranh giới nhị phân giữa hai token liên tiếp trong câu/dòng
Beginning-Inside-Outside	BIO	Lược đồ gán nhãn chuỗi chuẩn dùng để xác định điểm bắt đầu, bên trong và bên ngoài thực thể
Masked Language Modeling	MLM	Mô hình hóa ngôn ngữ che mặt nạ trên kênh văn bản

Thuật ngữ	**Viết tắt**	**Diễn giải**
Masked Image Modeling	MIM	Mô hình hóa hình ảnh che mặt nạ trên các mảnh ảnh
Word-Patch Alignment	WPA	Mục tiêu tiền huấn luyện căn chỉnh sự tương ứng giữa từ văn bản và mảnh ảnh
Robotic Process Automation	RPA	Tự động hóa quy trình nghiệp vụ bằng phần mềm robot

Danh sách hình vẽ

2.1 Kiến trúc tổng thể và các mục tiêu tiền huấn luyện hợp nhất của mô hình LayoutLMv3 [2]. 11

3.1 Kiến trúc tổng thể của khung mô hình LayoutLMv3 nhận thức cấu trúc cho bài toán Trích xuất thông tin chính KIE trên tài liệu giàu thị giác, tích hợp: (1) Mã hóa vị trí phân cấp HPE, (2) Bộ mã hóa xương sống LayoutLMv3 đa phương thức, (3) Mô-đun ngữ cảnh phân đoạn hai nhánh SCM kết hợp cổng dư ReZero, (4) Nhánh tắt bảo toàn độ mịn mức token, và (5) Bộ dung hợp trễ có cổng mặt nạ cấu trúc tối ưu đồng thời bởi hàm mất mát phân loại và hàm mất mát ranh giới nội dòng. 19

4.1 So sánh hiệu năng và độ ổn định qua 3 hạt giống ngẫu nhiên giữa mô hình cơ sở và mô hình đề xuất trên tập dữ liệu FUNSD. 32

Danh sách bảng

2.1 Đối sánh kiến trúc giữa các mô hình KIE tiêu biểu và mô hình đề xuất Structure-Aware LayoutLMv3. 16

4.1 Môi trường phần cứng phục vụ thực nghiệm cho khóa luận. 26
4.2 Thống kê chi tiết hai bộ dữ liệu thực nghiệm FUNSD và CORD. . 28
4.3 Kết quả thực nghiệm chi tiết trên từng hạt giống ngẫu nhiên (Seeds 42, 123, 1993) đã hoàn tất trên hệ thống NVIDIA A100-SXM4-80GB. 31
4.4 So sánh điểm F1 mức thực thể (%) trên FUNSD và CORD với các mô hình tiêu biểu đã công bố. 33
4.5 Bảng theo dõi kết quả thực nghiệm và nghiên cứu cắt giảm trên máy chủ NVIDIA A100-SXM4-80GB. 35
4.6 Kết quả nghiên cứu cắt giảm thành phần trên biến thể `LayoutLMv3-base`. 36
4.7 Phân tích chi tiết các nhóm lỗi mức thực thể trên tập kiểm thử FUNSD (1,998 thực thể chuẩn). 36
4.8 Phân tích định tính các dạng lỗi của mô hình cơ sở và cơ chế khắc phục của mô hình đề xuất. 37

Mở đầu

Trong kỷ nguyên chuyển đổi số hiện nay, hàng tỷ tài liệu nghiệp vụ như hóa đơn tài chính, biên lai bán lẻ, hợp đồng pháp lý, biểu mẫu hành chính và hồ sơ y tế được lưu hành mỗi ngày dưới dạng ảnh quét hoặc tệp PDF tĩnh. Khác với văn bản thuần túy có cấu trúc tuyến tính một chiều, các tài liệu giàu thị giác VRD (Visually Rich Documents) truyền tải ngữ nghĩa thông qua sự giao thoa chặt chẽ giữa nội dung ngôn ngữ, bố cục hình học hai chiều (như bảng biểu, cột dọc, các khối khóa – giá trị) và các tín hiệu thị giác (như phông chữ, độ đậm nhạt, đường kẻ phân cách) [1, 2]. Do đó, bài toán Trích xuất thông tin chính KIE (Key Information Extraction) nhằm tự động nhận diện và phân loại các trường thông tin quan trọng từ VRD đã trở thành một trong những bài toán cốt lõi của lĩnh vực Trí tuệ nhân tạo cho Tài liệu Document AI.

Sự ra đời của các mô hình Transformer đa phương thức tiền huấn luyện, đặc biệt là LayoutLM [3], LayoutLMv2 [4] và LayoutLMv3 [2], đã thiết lập chuẩn mực mới cho bài toán KIE thông qua việc phát biểu KIE dưới dạng bài toán gán nhãn chuỗi ở mức token theo lược đồ BIO (Beginning-Inside-Outside). Tuy nhiên, khi triển khai thực tế trên các biểu mẫu phức tạp hoặc hóa đơn nhiều cột, mô hình LayoutLMv3 nguyên bản bộc lộ những điểm yếu cố hữu về nhận thức cấu trúc vĩ mô và tính nhất quán ranh giới thực thể. Thứ nhất, việc chỉ cung cấp tọa độ hộp giới hạn (x_0, y_0, x_1, y_1) rời rạc buộc cơ chế tự chú ý phải tự suy diễn ngầm định các cấu trúc dòng, khối và cột. Thứ hai, việc dự đoán nhãn độc lập cho từng token mà thiếu sự trao đổi thông tin trực tiếp ở cấp độ phân đoạn dễ dẫn đến hiện tượng "trôi nhãn BIO" ở các thực thể văn bản dài hoặc sự nhầm lẫn giữa các vùng phụ thuộc ngữ cảnh lân cận (như `HEADER` và `QUESTION` trong biểu mẫu). Thứ ba, ranh giới chuyển tiếp giữa hai thực thể liền kề trên cùng một dòng thường không có ràng buộc giám sát trực tiếp, làm phát sinh lỗi cắt cụt hoặc nối gộp thực thể.

Nhận thấy những hạn chế trên, khóa luận này tập trung nghiên cứu và phát triển

khung kiến trúc mở rộng nhận thức cấu trúc trên nền tảng LayoutLMv3 (triển khai trong mô hình `LayoutLMv3ForSegmentTokenClassification`) tích hợp đồng thời ba kỹ thuật cải tiến: Mã hóa vị trí phân cấp HPE (Hierarchical Position Encoding), Mô-đun ngữ cảnh phân đoạn SCM (Segment Context Module) có cổng dư ReZero, và Hàm mất mát ranh giới nội dòng/thực thể. Kết quả thực nghiệm kiểm chứng qua 3 hạt giống ngẫu nhiên trên hạ tầng tính toán hiệu năng cao NVIDIA A100-SXM4-80GB với hai tập dữ liệu chuẩn FUNSD [5] và CORD [6] cho thấy phương pháp đề xuất cải thiện rõ rệt cả độ chính xác F1 mức thực thể lẫn độ ổn định hội tụ so với mô hình cơ sở.

Nội dung của khóa luận được trình bày theo cấu trúc 5 chương như sau:

Chương 1: Giới thiệu tổng quan về Trí tuệ nhân tạo cho Tài liệu Document AI, bài toán Trích xuất thông tin chính KIE, các thách thức cốt lõi trong KIE và phát biểu bài toán cụ thể mà khóa luận giải quyết.

Chương 2: Trình bày cơ sở lý thuyết và các công trình nghiên cứu liên quan, bao gồm kiến trúc Transformer đa phương thức, mô hình cơ sở LayoutLMv3 và nền tảng của phương pháp đề xuất.

Chương 3: Trình bày chi tiết phương pháp và kiến trúc mô hình đề xuất, bao gồm cơ sở toán học và thuật toán của Mã hóa vị trí phân cấp HPE, Mô-đun ngữ cảnh phân đoạn SCM và Hàm mất mát ranh giới thực thể.

Chương 4: Trình bày môi trường thực nghiệm, bộ dữ liệu chuẩn, các chỉ số đánh giá, cấu hình huấn luyện cũng như kết quả thực nghiệm và nghiên cứu cắt giảm thành phần.

Kết luận: Tóm lược những kết quả đạt được của khóa luận, phân tích các hạn chế và đề xuất định hướng phát triển trong tương lai.

Chương 1

Giới thiệu

1.1 Trí tuệ nhân tạo cho Tài liệu và Trích xuất thông tin chính KIE (Key Information Extraction)

Trí tuệ nhân tạo cho Tài liệu Document AI là lĩnh vực nghiên cứu liên ngành kết hợp giữa Xử lý ngôn ngữ tự nhiên NLP (Natural Language Processing), Thị giác máy tính và Học sâu nhằm tự động đọc, hiểu và trích xuất dữ liệu có cấu trúc từ các tài liệu kỹ thuật số hoặc ảnh chụp tài liệu [1]. Đối tượng trung tâm của Document AI là các **Tài liệu giàu thị giác VRD (Visually Rich Documents)**, bao gồm hóa đơn GTGT, biên lai thanh toán, biểu mẫu đăng ký, báo cáo tài chính và hồ sơ hành chính.

Ở thời điểm bất kỳ trong một quy trình số hóa doanh nghiệp hoặc Tự động hóa quy trình bằng robot RPA (Robotic Process Automation), hệ thống nhận đầu vào là một ảnh tài liệu $\mathcal{I}$ đi kèm với tập hợp gồm M từ (hoặc vùng văn bản) được trích xuất thông qua hệ thống Nhận dạng ký tự quang học OCR (Optical Character Recognition):

$$\mathcal{O} = \{(w_m, \mathbf{b}_m)\}_{m=1}^{M}, \tag{1.1}$$

trong đó w_m là chuỗi ký tự của từ thứ m và $\mathbf{b}_m = \left(x_0^{(m)}, y_0^{(m)}, x_1^{(m)}, y_1^{(m)}\right) \in [0, 1000]^4$ biểu diễn tọa độ hộp giới hạn hai chiều đã chuẩn hóa theo kích thước trang tài liệu (với (x_0, y_0) là góc trên bên trái và (x_1, y_1) là góc dưới bên phải).

Trích xuất thông tin chính KIE (Key Information Extraction) là tác vụ trọng tâm bậc nhất trên VRD [5, 6, 2]. Mục tiêu của KIE là tự động xác định

các cụm từ mang thông tin nghiệp vụ cốt lõi (chẳng hạn như tên mặt hàng, đơn giá, tổng tiền thanh toán trên biên lai; hoặc tiêu đề biểu mẫu, câu hỏi và câu trả lời tương ứng trên tờ khai) và phân loại chúng vào tập các thực thể ngữ nghĩa $\mathcal{E} = \{e_1, e_2, \ldots, e_K\}$ được định nghĩa trước. Trong hầu hết các hệ thống hiện đại, KIE được phát biểu dưới dạng bài toán **gán nhãn chuỗi ở mức token** sử dụng lược đồ gán nhãn BIO (*Beginning-Inside-Outside*):

- Nhãn B-c: Đánh dấu token bắt đầu của một thực thể thuộc loại $c \in \mathcal{E}$.
- Nhãn I-c: Đánh dấu token nằm bên trong (tiếp nối) của thực thể thuộc loại $c \in \mathcal{E}$.
- Nhãn O: Đánh dấu token không thuộc bất kỳ trường thông tin cần trích xuất nào (văn bản nền hoặc ký hiệu nhiễu).

Một thực thể dự đoán chỉ được tính là hoàn toàn chính xác khi và chỉ khi cả loại thực thể c lẫn điểm bắt đầu (B-c) và toàn bộ chuỗi tiếp nối (I-c) của nó trùng khớp tuyệt đối với nhãn chuẩn ground-truth [5].

1.2 Các vấn đề thách thức trong Trích xuất thông tin chính

1.2.1 Hạn chế của biểu diễn tọa độ phẳng hai chiều

Các mô hình tiền huấn luyện tài liệu kinh điển như LayoutLM [3], LayoutLMv2 [4] và LayoutLMv3 [2] nhúng thông tin bố cục bằng cách tra cứu tọa độ hộp (x_0, y_0, x_1, y_1) cùng kích thước (w, h) vào các bảng nhúng vị trí 2D. Mặc dù cách tiếp cận này cung cấp vị trí điểm ảnh chính xác cho từng token, nó lại xem tài liệu như một mặt phẳng tọa độ rời rạc và bỏ qua **cấu trúc phân cấp logic vĩ mô** của trang văn bản:

1. **Cấu trúc dòng ngang:** Trên các tài liệu quét bị nghiêng nhẹ hoặc có khoảng cách dòng nhỏ, hai từ nằm trên cùng một dòng ngang có thể có tung độ y chênh lệch nhỏ, buộc mạng tự chú ý toàn cục phải tự học quy tắc căn dòng từ dữ liệu thô.
2. **Cấu trúc khối cục bộ:** Các đoạn văn bản hoặc cụm trường khóa – giá trị tạo thành từng vùng ngữ nghĩa khép kín nhưng không được phân tách tường minh trong không gian nhúng tọa độ phẳng.

3. **Cấu trúc cột dọc:** Trong hóa đơn bán lẻ (như bộ dữ liệu CORD) hoặc biểu mẫu đa cột (như bộ dữ liệu FUNSD), các trường cùng vai trò ngữ nghĩa (ví dụ: cột số lượng, cột đơn giá, cột thành tiền) luôn thẳng hàng theo trục dọc x. Khi thiếu chỉ báo cột tường minh, mô hình dễ nhầm lẫn giữa các trường số học nằm ở các cột khác nhau.

1.2.2 Hiện tượng trôi nhãn BIO và xung đột độ mịn phân đoạn – token

Trong các mô hình phân biệt dựa trên nền tảng LayoutLMv3, dù các token có trao đổi thông tin thông qua các lớp Transformer tự chú ý, đầu phân loại cuối cùng vẫn đưa ra quyết định dự đoán nhãn độc lập cho từng token thứ i dựa trên véc-tơ ẩn $\mathbf{h}_i$. Cách thiết kế này dẫn đến hai dạng lỗi phổ biến trong thực nghiệm:

- **Hiện tượng trôi nhãn BIO trong thực thể dài:** Đối với các thực thể tự do gồm nhiều từ (ví dụ: một đoạn văn bản trả lời dài hàng chục token thuộc nhãn `ANSWER` trên tập dữ liệu FUNSD), mô hình có thể dự đoán đúng các token đầu là B-ANSWER, I-ANSWER, nhưng đến giữa câu lại chuyển đột ngột sang O hoặc I-QUESTION. Chỉ cần một token giữa chuỗi bị lệch nhãn, toàn bộ thực thể dài đó sẽ bị đánh giá là sai hoàn toàn theo chuẩn đánh giá F1 mức thực thể nghiêm ngặt.

- **Nhầm lẫn toàn bộ phân đoạn do thiếu ngữ cảnh lân cận:** Nhiều phân đoạn ngắn có nội dung từ vựng gần giống nhau (ví dụ: cụm từ *"Date:"* hoặc *"Name:"* vừa có thể là tiêu đề mục `HEADER`, vừa có thể là câu hỏi `QUESTION` tùy thuộc vào việc phân đoạn liền kề phía sau nó là một ô điền câu trả lời `ANSWER` hay là một mục con).

Một giải pháp tự nhiên để khắc phục hiện tượng trôi nhãn là thực hiện gộp toàn bộ các token thuộc cùng một phân đoạn cấu trúc thành một véc-tơ đại diện duy nhất trước khi phân loại. Tuy nhiên, trong quá trình khảo sát và phát triển kiến trúc của khóa luận, việc gộp cứng này làm nảy sinh **xung đột giữa cấu trúc vĩ mô và độ mịn cục bộ**: nếu mọi token trong cùng phân đoạn chỉ nhận đúng một véc-tơ gộp giống hệt nhau, bộ phân loại sẽ mất đi khả năng phân biệt giữa token khởi đầu (B-c) và các token tiếp nối (I-c), cũng như làm mờ đi ranh giới giữa các thực thể con nằm chung trong một dòng OCR.

1.2.3 Sự bất định tại ranh giới chuyển tiếp thực thể nội dòng

Trên các hóa đơn và biểu mẫu thực tế, hệ thống OCR hoặc bộ tách dòng đôi khi ghép hai thực thể khác nhau nằm gần nhau trên cùng một dòng ngang (ví dụ: số lượng mặt hàng `MENU.CNT` nằm sát tên mặt hàng `MENU.NM`, hoặc cặp nhãn câu hỏi `QUESTION` và nội dung trả lời `ANSWER` viết liền trên một dòng). Khi hàm mục tiêu huấn luyện chỉ sử dụng duy nhất mất mát Entropy chéo trên từng vị trí token độc lập, mô hình không bị phạt trực tiếp khi tạo ra các biểu diễn ẩn $\mathbf{h}_i$ và $\mathbf{h}_{i+1}$ quá giống nhau tại điểm chuyển tiếp giữa hai thực thể khác nhau, hoặc quá khác biệt ở bên trong cùng một thực thể liên tục.

1.3 Các hướng tiếp cận chính trong bài toán KIE

1.3.1 Ba nhóm kiến trúc phổ biến cho hiểu tài liệu giàu thị giác

Dựa trên cách thức khai thác và tích hợp các phương thức dữ liệu (văn bản, bố cục 2D, hình ảnh), các phương pháp giải quyết bài toán KIE hiện nay có thể được phân thành ba nhóm chính [1, 7]:

Nhóm mô hình chỉ dựa trên văn bản một chiều

Nhóm phương pháp đầu tiên sử dụng trực tiếp các mô hình ngôn ngữ tiền huấn luyện như BERT [8] hoặc RoBERTa trên chuỗi các từ thu được từ OCR đã sắp xếp theo thứ tự đọc từ trái sang phải, từ trên xuống dưới. Với tập chuỗi token đầu vào $X = (x_1, x_2, \ldots, x_L)$, mô hình học ánh xạ $f_{\text{text}} : X \to \mathcal{Y}^L$. Ưu điểm của hướng tiếp cận này là cấu trúc đơn giản và tốc độ suy luận nhanh. Tuy nhiên, vì hoàn toàn bỏ qua tọa độ không gian 2D và thông tin thị giác, hiệu năng của chúng suy giảm nghiêm trọng khi cấu trúc bảng biểu hoặc nhiều cột phá vỡ thứ tự đọc tuyến tính (chẳng hạn BERT chỉ đạt 60.26% F1 trên tập dữ liệu biểu mẫu FUNSD [2]).

Nhóm mô hình đa phương thức tiền huấn luyện nhận thức bố cục

Để khắc phục hạn chế của mô hình văn bản thuần túy, nhóm phương pháp thứ hai tích hợp trực tiếp tọa độ hộp giới hạn 2D và đặc trưng ảnh tài liệu vào kiến trúc Transformer:

- **Dòng họ LayoutLM:** LayoutLM [3] tiên phong bổ sung lớp nhúng vị trí 2D (x_0, y_0, x_1, y_1) vào bộ mã hóa BERT. LayoutLMv2 [4] và DocFormer [9] tích hợp thêm mạng tích chập CNN ResNeXt-FPN để trích xuất bản đồ đặc trưng thị giác kết hợp với độ lệch tự chú ý nhận thức không gian. LayoutLMv3 [2] đơn giản hóa và thống nhất kiến trúc bằng cách thay thế hoàn toàn mạng CNN nặng nề bằng phép nhúng mảnh ảnh tuyến tính và tiền huấn luyện với mục tiêu che mặt nạ hợp nhất trên cả văn bản MLM (Masked Language Modeling), hình ảnh MIM (Masked Image Modeling) và căn chỉnh từ – mảnh ảnh WPA (Word-Patch Alignment).

- **Các mô hình tăng cường cấu trúc và hình học:** StructuralLM [10] khai thác vị trí mức ô; BROS [11] mã hóa vị trí tương đối giữa các khối văn bản trong không gian 2D; LiLT [12] tách biệt luồng xử lý bố cục và văn bản qua cơ chế tương tác hai chiều; trong khi GeoLayoutLM [13] và GraphLayoutLM [14] sử dụng các ràng buộc hình học đa mức hoặc mạng đồ thị bố cục trong giaiền huấn luyện.

Nhóm mô hình ngôn ngữ lớn sinh tự hồi quy LLM (Large Language Model)

Gần đây, các mô hình ngôn ngữ lớn đa phương thức như LayoutLLM [15] và DocLLM [16] phát biểu lại bài toán KIE dưới dạng tác vụ sinh văn bản tự hồi quy. Dù có khả năng suy luận ngữ nghĩa mạnh mẽ trên chuỗi dài, các kiến trúc sinh tự hồi quy đòi hỏi chi phí tính toán và dung lượng bộ nhớ GPU rất lớn, gây khó khăn cho các hệ thống RPA doanh nghiệp yêu cầu độ trễ thấp. Quan trọng hơn, quá trình giải mã sinh văn bản bị tách rời khỏi tọa độ hộp giới hạn đầu vào, dẫn tới nguy cơ ảo giác hoặc không thể ánh xạ chính xác chuỗi văn bản sinh ra quay ngược về tọa độ OCR gốc trên trang tài liệu [16, 15]. Vì vậy, việc nâng cao khả năng nhận thức cấu trúc cho các mô hình phân biệt gọn nhẹ như LayoutLMv3 ở giai đoạn tinh chỉnh mang ý nghĩa thực tiễn rất cao.

1.3.2 Các chiến lược mô hình hóa cấu trúc ở giai đoạn tinh chỉnh

Để tăng cường nhận thức cấu trúc cho mô hình phân biệt mà không phải gánh chịu chi phí tiền huấn luyện lại trên hàng triệu trang tài liệu, các chiến lược thích

ứng ở giai đoạn tinh chỉnh tập trung vào ba hướng chính:

1. **Làm giàu không gian nhúng đầu vào:** Phân cụm các token theo cấu trúc hình học (dòng, khối, cột) và bổ sung các véc-tơ nhúng phân cấp tương ứng vào đầu vào của mạng xương sống.

2. **Mô hình hóa ngữ cảnh mức phân đoạn:** Tổng hợp thông tin của các token trong cùng một vùng cấu trúc thành biểu diễn mức phân đoạn, cho phép các phân đoạn lân cận trao đổi thông tin theo thứ tự đọc trước khi phản hồi ngược về từng token.

3. **Giám sát phụ trợ về ranh giới và hình học:** Bổ sung các hàm mất mát phụ trợ (như mất mát phân định ranh giới thực thể hoặc tách biệt không gian ngữ nghĩa – hình học) nhằm định hướng cho mạng xương sống học được các biểu diễn ẩn sắc nét hơn tại các biên chuyển tiếp thực thể.

1.4 Bài toán đồ án

Từ những phân tích về hạn chế của mô hình LayoutLMv3 nguyên bản cũng như yêu cầu thực tiễn của bài toán KIE trên tài liệu giàu thị giác, mục tiêu của khóa luận là nghiên cứu, thiết kế và kiểm chứng thực nghiệm một kiến trúc mở rộng gọn nhẹ trên nền tảng LayoutLMv3 (gồm cả hai biến thể `layoutlmv3-base` và `layoutlmv3-large`). Kiến trúc đề xuất giải quyết đồng thời bài toán thiếu hụt cấu trúc vĩ mô, hiện tượng trôi nhãn BIO trong phân đoạn đa token và sự nhập nhằng tại ranh giới chuyển tiếp thực thể thông qua ba thành phần: **Mã hóa vị trí phân cấp HPE (Hierarchical Position Encoding)**, **Mô-đun ngữ cảnh phân đoạn SCM (Segment Context Module)** và **Hàm mất mát ranh giới nội dòng**.

Bài toán cụ thể mà khóa luận giải quyết được phát biểu hình thức như sau:
Đầu vào: Một tài liệu giàu thị giác $\mathcal{D} = (\mathcal{I}, \mathcal{T}, \mathcal{B}, \mathcal{S})$, trong đó:

- $\mathcal{I} \in \mathbb{R}^{3\times H_{\text{img}}\times W_{\text{img}}}$ là ảnh màu RGB của trang tài liệu (được chuẩn hóa kích thước về 224×224).

- $\mathcal{T} = (t_1, t_2, \ldots, t_L)$ là chuỗi gồm L token văn bản sau khi phân tách từ subword từ kết quả OCR.

- $\mathcal{B} = (\mathbf{b}_1, \mathbf{b}_2, \ldots, \mathbf{b}_L)$ với $\mathbf{b}_i = (x_0^{(i)}, y_0^{(i)}, x_1^{(i)}, y_1^{(i)}) \in [0, 1000]^4$ là tọa độ hộp giới hạn chuẩn hóa của từng token t_i.

- $\mathcal{S} = (s_1, s_2, \ldots, s_L)$ với $s_i \in \{-1, 0, 1, \ldots, K-1\}$ là chỉ số phân đoạn gán theo thứ tự đọc cho các token cùng thuộc một vùng/dòng OCR.

Đầu ra: Chuỗi nhãn dự đoán $\hat{\mathbf{Y}} = (\hat{y}_1, \hat{y}_2, \ldots, \hat{y}_L)$ với $\hat{y}_i \in \mathcal{Y}_{\text{BIO}} = \{\text{O}\} \cup \{\text{B-}c, \text{I-}c \mid c \in \mathcal{E}\}$ sao cho tập hợp các thực thể trích xuất được (xác định bởi cả loại thực thể c và đoạn vị trí bắt đầu – kết thúc) đạt độ chính xác F1 mức thực thể và độ ổn định cao nhất trên các tập dữ liệu kiểm thử chuẩn FUNSD và CORD.

Chương 2

Các kỹ thuật liên quan

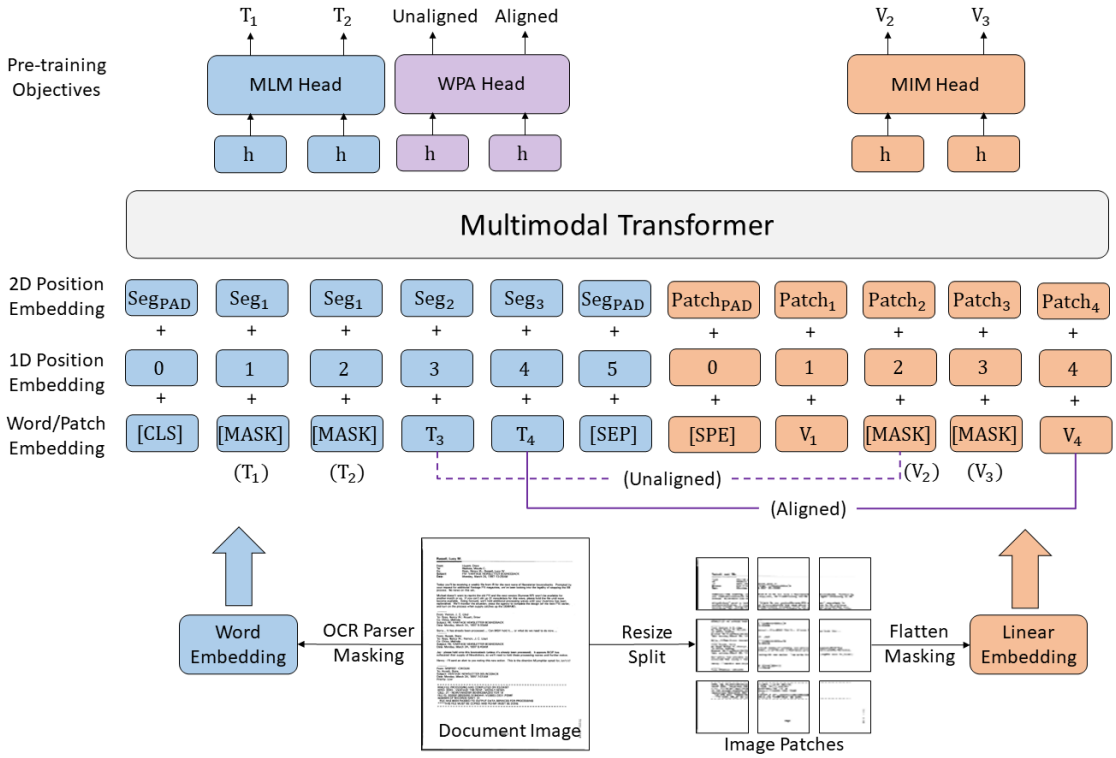
Trong chương này, khóa luận trình bày chi tiết cơ sở lý thuyết và các nghiên cứu liên quan trực tiếp làm nền tảng phát triển phương pháp đề xuất: (1) Kiến trúc nền tảng đa phương thức **LayoutLMv3** [2] cho bài toán hiểu tài liệu giàu thị giác; (2) Các hướng tiếp cận mô hình hóa cấu trúc hình học và ngữ cảnh phân đoạn trong Document AI; và (3) Phân tích xung đột độ mịn giữa cấp độ token và cấp độ phân đoạn trong bài toán KIE discriminative.

2.1 Mô hình nền tảng đa phương thức LayoutLMv3

LayoutLMv3 [2], được đề xuất bởi Huang và cộng sự tại hội nghị ACM Multimedia 2022, là mô hình nền tảng đa phương thức tiêu biểu nhất cho các tác vụ Document AI. Khác với các thế hệ tiền nhiệm như LayoutLMv2 [4] hay DocFormer [9] vốn phụ thuộc vào mạng xương sống thị giác CNN phức tạp (như ResNeXt-101-FPN) và quy trình phát hiện vùng ảnh tốn kém, LayoutLMv3 sử dụng một bộ mã hóa Transformer hợp nhất duy nhất nhận đầu vào trực tiếp là các token văn bản kết hợp với chuỗi mảnh ảnh tuyến tính. Tổng quan kiến trúc và các mục tiêu tiền huấn luyện của LayoutLMv3 được minh họa trong Hình 2.1.

2.1.1 Biểu diễn nhúng văn bản và không gian hai chiều

Đối với kênh văn bản, mỗi tài liệu được biểu diễn bởi chuỗi gồm L token sau khi phân tách từ bằng bộ từ vựng Byte-Level BPE (tương tự RoBERTa). Với mỗi token thứ $i \in \{1, \ldots, L\}$, biểu diễn nhúng cơ sở $\mathbf{e}_i^{\text{base}} \in \mathbb{R}^{d_{\text{model}}}$ (trong đó $d_{\text{model}} = 768$ đối với bản `base` và $d_{\text{model}} = 1024$ đối với bản `large`) được tổng hợp từ ba thành



Hình 2.1: Kiến trúc tổng thể và các mục tiêu tiền huấn luyện hợp nhất của mô hình LayoutLMv3 [2].

phần:

1. **Nhúng từ vựng:** $\mathbf{e}_i^{\text{word}} = \mathbf{E}_{\text{word}}(t_i) \in \mathbb{R}^{d_{\text{model}}}$ ánh xạ mã định danh từ vựng t_i sang không gian véc-tơ liên tục.

2. **Nhúng vị trí một chiều:** $\mathbf{e}_i^{\text{1D}} = \mathbf{E}_{\text{pos1D}}(i) \in \mathbb{R}^{d_{\text{model}}}$ biểu diễn thứ tự tuần tự của token trong chuỗi đầu vào.

3. **Nhúng vị trí không gian hai chiều:** Thay vì gán tọa độ riêng lẻ cho từng từ con, LayoutLMv3 áp dụng cơ chế bố cục mức phân đoạn: các từ cùng thuộc một dòng/phân đoạn OCR chia sẻ chung một hộp giới hạn bao quanh $\mathbf{b}_i = (x_0, y_0, x_1, y_1) \in [0, 1000]^4$ cùng chiều rộng $w = \text{clip}(x_1 - x_0, 0, 1023)$ và chiều cao $h = \text{clip}(y_1 - y_0, 0, 1023)$. Sáu giá trị hình học này được tra cứu qua các bảng nhúng tọa độ $\mathbf{E}_x, \mathbf{E}_y \in \mathbb{R}^{1024 \times d_{\text{coord}}}$ và bảng nhúng kích thước $\mathbf{E}_w, \mathbf{E}_h \in \mathbb{R}^{1024 \times d_{\text{shape}}}$ rồi ghép nối lại thành véc-tơ không gian $\mathbf{e}_i^{\text{2D}} \in \mathbb{R}^{d_{\text{model}}}$:

$$\mathbf{e}_i^{\text{2D}} = [\mathbf{E}_x(x_0) \parallel \mathbf{E}_y(y_0) \parallel \mathbf{E}_x(x_1) \parallel \mathbf{E}_y(y_1) \parallel \mathbf{E}_h(h) \parallel \mathbf{E}_w(w)], \tag{2.1}$$

với $4d_{\text{coord}} + 2d_{\text{shape}} = d_{\text{model}}$ (cụ thể trong `layoutlmv3-base`, $d_{\text{coord}} =$

$128, d_{\text{shape}} = 128 \Rightarrow 4 \times 128 + 2 \times 128 = 768$).

Khi đó, véc-tơ nhúng văn bản chuẩn hóa của token thứ i (cài đặt trong lớp `LayoutLMv3Embeddings`) được tính bởi công thức:

$$\mathbf{x}_i^{\text{text}} = \text{Dropout}\big(\text{LayerNorm}\big(\mathbf{e}_i^{\text{word}} + \mathbf{e}_i^{\text{type}} + \mathbf{e}_i^{\text{1D}} + \mathbf{e}_i^{\text{2D}}\big)\big), \tag{2.2}$$

trong đó $\mathbf{e}_i^{\text{type}}$ là nhúng kiểu token (mặc định bằng $\mathbf{0}$).

2.1.2 Biểu diễn nhúng mảnh ảnh thị giác

Đối với kênh hình ảnh, ảnh tài liệu $\mathcal{I}$ được thay đổi kích thước về $H_{\text{img}} \times W_{\text{img}} = 224 \times 224$ và chuẩn hóa theo trung bình và độ lệch chuẩn của ImageNet Inception. Mô-đun `PatchEmbed` chia ảnh thành lưới các mảnh vuông không giao nhau kích thước $P \times P = 16 \times 16$, tạo ra $M_{\text{img}} = \frac{224}{16} \times \frac{224}{16} = 14 \times 14 = 196$ mảnh ảnh. Một phép tích chập hai chiều Conv2d$(3, d_{\text{model}}, \text{kernel_size} = 16, \text{stride} = 16)$ chiếu tuyến tính từng mảnh ảnh sang không gian d_{model}, sau đó cộng với nhúng vị trí ảnh 1D học được và ghép thêm 1 token phân loại thị giác $\texttt{[CLS]}_{\text{vis}}$ ở đầu chuỗi, thu được tổng cộng $M_{\text{vis}} = 197$ token thị giác:

$$\mathbf{X}^{\text{vis}} = \big[\mathbf{x}_{\text{CLS}}^{\text{vis}}, \mathbf{x}_1^{\text{vis}}, \ldots, \mathbf{x}_{196}^{\text{vis}}\big] \in \mathbb{R}^{197 \times d_{\text{model}}}. \tag{2.3}$$

Chuỗi văn bản $\mathbf{X}^{\text{text}} \in \mathbb{R}^{L \times d_{\text{model}}}$ và chuỗi thị giác $\mathbf{X}^{\text{vis}} \in \mathbb{R}^{197 \times d_{\text{model}}}$ được ghép nối dọc theo chiều độ dài chuỗi thành chuỗi đa phương thức hợp nhất $\mathbf{H}^{(0)} = [\mathbf{X}^{\text{text}} \parallel \mathbf{X}^{\text{vis}}] \in \mathbb{R}^{(L+197) \times d_{\text{model}}}$ để đưa vào bộ mã hóa Transformer.

2.1.3 Cơ chế tự chú ý nhận thức không gian và ổn định hóa CogView

Bộ mã hóa của LayoutLMv3 gồm N_{layer} lớp Transformer xếp chồng ($N_{\text{layer}} = 12, N_{\text{head}} = 12$ ở bản `base`; $N_{\text{layer}} = 24, N_{\text{head}} = 16$ ở bản `large`). Để nắm bắt quan hệ vị trí tương đối giữa các token trên trang tài liệu, lớp `LayoutLMv3SelfAttention` bổ sung hai ma trận độ lệch chú ý tương đối vào tích vô hướng giữa truy vấn $\mathbf{Q}$ và khóa $\mathbf{K}$:

$$\mathbf{A}_{i,j} = \frac{\mathbf{q}_i \mathbf{k}_j^\top}{\sqrt{d_h}} + \frac{b_{i,j}^{\text{1D}} + b_{i,j}^{\text{2D}}}{\sqrt{d_h}} + \mathbf{M}_{i,j}^{\text{mask}}, \tag{2.4}$$

trong đó $d_h = d_{\text{model}}/N_{\text{head}}$ là số chiều của mỗi đầu chú ý, $b_{i,j}^{\text{1D}}$ là độ lệch vị trí tương đối 1D được phân giỏ từng đoạn theo khoảng cách chỉ số $|i - j|$, và $b_{i,j}^{\text{2D}}$ là độ lệch vị trí tương đối không gian 2D tính theo khoảng cách tâm hộp giới hạn theo cả hai trục $(\Delta x, \Delta y)$.

Đặc biệt, nhằm ngăn chặn hiện tượng tràn số học khi tính hàm Softmax trên các điểm số chú ý $\mathbf{A}_{i,j}$ có biên độ lớn, LayoutLMv3 áp dụng kỹ thuật giãn nút cổ chai độ chính xác **PB-Relax (Precision Bottleneck Relaxation)** của CogView [17] với hệ số $\alpha_{\text{cog}} = 32$:

$$\text{AttentionProbs}(\mathbf{A}) = \text{Softmax}\left(\alpha_{\text{cog}}\left(\frac{\mathbf{A}}{\alpha_{\text{cog}}} - \max_k\left(\frac{\mathbf{A}_{:,k}}{\alpha_{\text{cog}}}\right)\right)\right). \tag{2.5}$$

2.1.4 Ba mục tiêu tiền huấn luyện hợp nhất của LayoutLMv3

Như thể hiện trên Hình 2.1, LayoutLMv3 được tiền huấn luyện tự giám sát trên 11 triệu trang tài liệu thuộc tập IIT-CDIP thông qua tổng của ba hàm mất mát:

1. **Mô hình hóa ngôn ngữ che mặt nạ MLM (Masked Language Modeling):** Che ngẫu nhiên 30% số token văn bản theo phương pháp che theo cụm với độ dài cụm tuân theo phân phối Poisson ($\lambda = 3$) và huấn luyện mô hình khôi phục lại các token bị che dựa trên ngữ cảnh hình ảnh và văn bản xung quanh ($\mathcal{L}_{\text{MLM}}$).

2. **Mô hình hóa hình ảnh che mặt nạ MIM (Masked Image Modeling):** Che ngẫu nhiên 40% số mảnh ảnh theo thuật toán che khối và dự đoán mã token thị giác rời rạc tương ứng được sinh bởi bộ tự mã hóa biến phân rời rạc (dVAE) ($\mathcal{L}_{\text{MIM}}$).

3. **Căn chỉnh Từ – Mảnh ảnh WPA (Word-Patch Alignment):** Để thiết lập liên kết đa phương thức chặt chẽ giữa văn bản và hình ảnh, đầu phân loại nhị phân WPA dự đoán xem mảnh ảnh tương ứng về mặt hình học với một token văn bản không bị che hiện đang ở trạng thái *được căn chỉnh* hay *không căn chỉnh* ($\mathcal{L}_{\text{WPA}}$).

Tổng hàm mất mát tiền huấn luyện của LayoutLMv3 là:

$$\mathcal{L}_{\text{pretrain}} = \mathcal{L}_{\text{MLM}} + \mathcal{L}_{\text{MIM}} + \mathcal{L}_{\text{WPA}}. \tag{2.6}$$

2.2 Các hướng nghiên cứu liên quan trong Document AI và KIE

Bài toán Trích xuất thông tin chính KIE trên tài liệu giàu thị giác VRD đã phát triển qua nhiều giai đoạn đột phá, từ các đường ống OCR truyền thống đến các

mô hình nền tảng đa phương thức và cơ chế quy nạp cấu trúc:

2.2.1 Các mô hình Transformer nền tảng đa phương thức

Sự kết hợp giữa văn bản và bố cục 2D được khởi xướng bởi LayoutLM [3], sau đó mở rộng sang tích hợp đặc trưng thị giác CNN trong LayoutLMv2 [4] và DocFormer [9]. LayoutLMv3 [2] đã tối ưu hóa toàn diện đường ống huấn luyện bằng cách loại bỏ CNN, sử dụng trực tiếp các mảnh ảnh tuyến tính [18, 19] cùng các mục tiêu tiền huấn luyện hợp nhất (MLM, MIM, WPA). Bên cạnh đó, LiLT [12] nghiên cứu khả năng biểu diễn bố cục độc lập ngôn ngữ, còn LayoutMask [20] và UniDoc [21] tăng cường tương tác văn bản – bố cục qua học đối sánh.

2.2.2 Mô hình hóa cấu trúc hình học, đồ thị và thứ tự đọc

Do tọa độ 2D tuyệt đối chỉ phản ánh các điểm số rời rạc, StructuralLM [10] đề xuất nhúng mức ô để gắn kết các từ trong cùng một ô văn bản. BROS [11] mã hóa tọa độ và góc tương đối để khôi phục thứ tự đọc. FormNet [22] và USTC-iFLYTEK [23] ứng dụng mạng đồ thị chú ý để xâu chuỗi các thực thể phi tuần tự. Gần đây, ROAP [24] áp dụng thuật toán chia khoảng cách thích ứng XY-cut kết hợp ma trận chú ý tiên nghiệm gắn vào LayoutLMv3, chứng minh vai trò then chốt của việc lập mô hình thứ tự đọc logic.

2.2.3 Các công trình cải tiến trên nền tảng LayoutLMv3

Nhờ hiệu quả tham số và biểu diễn cơ sở vượt trội, LayoutLMv3 trở thành mạng xương sống hàng đầu cho các nghiên cứu mở rộng cấu trúc. AETNet [25] thiết kế mô-đun tăng cường liên kết đa phương thức và hàm mất mát căn chỉnh. OTCR [26] ứng dụng lý thuyết vận tải tối ưu để định tuyến các đặc trưng thị giác trọng yếu đến đúng token văn bản. DocExtractNet [27] tích hợp kỹ thuật P-Tuning gợi ý độ chính xác và mô-đun nâng cao chất lượng ảnh đầu vào. Tiếp nối hướng nghiên cứu này, khóa luận đề xuất tích hợp đồng thời Mã hóa vị trí phân cấp HPE, Mô-đun ngữ cảnh phân đoạn SCM có cổng ReZero và Hàm mất mát ranh giới.

2.2.4 Mô hình sinh LLM so với mô hình phân biệt chuỗi trong KIE

Sự bùng nổ của Mô hình ngôn ngữ lớn LLM kéo theo sự xuất hiện của các kiến trúc sinh như DONUT [28], DocLLM [16], LayoutLLM [15], LayTextLLM [29] và DocLayLLM [30]. Mặc dù các phương pháp LLM thể hiện khả năng suy luận zero-

shot ấn tượng, chúng đòi hỏi chi phí tính toán suy luận rất lớn và gặp khó khăn trong việc neo chính xác tọa độ trích xuất về hộp OCR [16]. Các hướng tiếp cận học trong ngữ cảnh như SAIL [31] hay tự sửa lỗi OCR như GENKIE [32] cũng tìm cách tận dụng LLM. Để dung hòa bài toán hiệu năng và chi phí, các khung kiến trúc lai như P2Net [33] và PM3-KIE [34] kết hợp mô hình nền tảng đóng băng với tầng suy luận xác suất. Trong các hệ thống RPA doanh nghiệp xử lý hàng triệu trang tài liệu mỗi ngày, các mô hình phân biệt chuỗi có định hướng cấu trúc vẫn là giải pháp thực tiễn và tối ưu nhất về độ trễ suy luận.

2.2.5 Trích xuất quan hệ và thích ứng tham số trong học sâu

Trong lĩnh vực trích xuất thông tin và học biểu diễn, các nghiên cứu của Phạm Thị Quỳnh Trang, Lê Đức Trọng và cộng sự [35] đã chứng minh việc duy trì mẫu biểu diễn nguyên mẫu giúp bảo toàn ranh giới thực thể và hạn chế suy giảm tri thức. Ngoài ra, kỹ thuật số học tác vụ Kolmogorov-Arnold định hướng [7] cũng chỉ ra tầm quan trọng của việc điều tiết tham số cục bộ khi tinh chỉnh mô hình lớn.

Bảng 2.1 tổng hợp và so sánh đặc điểm kiến trúc giữa các mô hình Document AI tiêu biểu với kiến trúc Structure-Aware LayoutLMv3 đề xuất trong khóa luận.

2.3 Định hướng và mục tiêu nghiên cứu của khóa luận

Qua phân tích sâu sắc cấu trúc mô hình LayoutLMv3 và các thách thức trên, khóa luận xác định ba bài toán trọng tâm cần giải quyết:

1. **Mã hóa vị trí phân cấp HPE:** Bổ sung chỉ số dòng, khối và cột với trọng số giảm chấn thích ứng nhằm dẫn dắt mô hình nhận biết cấu trúc hình học vĩ mô mà không làm rối loạn các trọng số tiền huấn luyện.

2. **Mô-đun ngữ cảnh phân đoạn SCM với cổng dư ReZero:** Gộp trung bình các token thành biểu diễn phân đoạn, lan truyền ngữ cảnh theo thứ tự đọc qua Transformer phân đoạn nhẹ, và dung hợp có kiểm soát bằng cổng dư ReZero [37] cùng véc-tơ nhúng đầu phân đoạn (`is_first_token_embedding`).

3. **Hàm mất mát ranh giới nội dòng/thực thể:** Áp dụng giám sát cặp token liền kề để triệt tiêu hiện tượng trôi nhãn và ranh giới mờ nhạt, đem lại độ

Bảng 2.1: Đối sánh kiến trúc giữa các mô hình KIE tiêu biểu và mô hình đề xuất Structure-Aware LayoutLMv3.

Mô hình / Phương pháp	**Xương sống thị giác**	**Mã hóa 2D không gian**	**Chú ý đoạn (SCM)**	**Cổng ReZero**	**Mất mát biên**
BERT [8] / RoBERTa [36]	Không (Chữ)	Không (1D)	Không	Không	Không
LayoutLM (v1) [3]	Faster R-CNN	Hộp từ 2D	Không	Không	Không
LayoutLMv2 [4]	ResNeXt-FPN	Hộp từ 2D	Không	Không	Không
StructuralLM [10]	Không	Hộp ô 2D	Mức ô (Cell)	Không	Không
Baseline LayoutLMv3 [2]	Mảnh ảnh	Đẳng hướng ($d/6$)	Dùng chung hộp	Không	Không
Đề xuất Structure-Aware	**Mảnh ảnh**	**HPE phân cấp ($d_x \neq d_y$)**	**Có** (SCM)	**Có** (α Gate)	**Có** ($\mathcal{L}_{\text{bound}}$)

chính xác cao và phương sai cực thấp trên các bộ dữ liệu chuẩn.

Chương 3

Phương pháp đề xuất

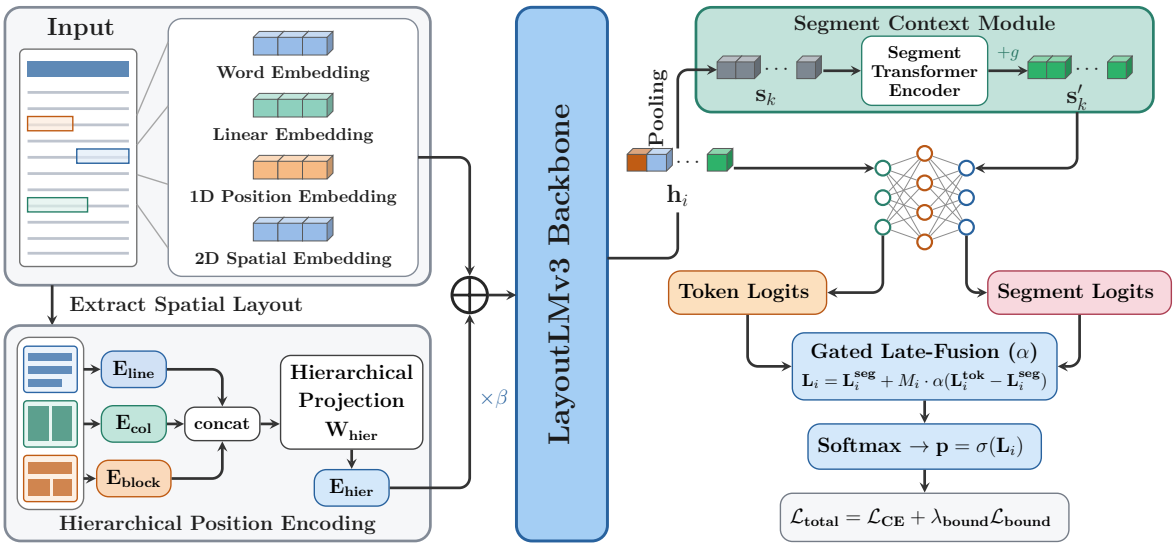
Như đã phân tích trong Chương 2, mô hình LayoutLMv3 [2] tuy sở hữu biểu diễn đa phương thức mạnh mẽ nhưng vẫn thiếu các chỉ báo cấu trúc phân cấp tường minh ở đầu vào, thiếu cơ chế trao đổi ngữ cảnh trực tiếp ở cấp độ phân đoạn và chưa có ràng buộc giám sát ranh giới giữa các cặp token liên tiếp. Để giải quyết triệt để ba vấn đề này, khóa luận xây dựng mô hình mở rộng định hướng cấu trúc (`LayoutLMv3ForSegmentTokenClassification`) bao gồm ba mô-đun cốt lõi hoạt động phối hợp: (1) **Mã hóa vị trí phân cấp HPE (Hierarchical Position Encoding)**, (2) **Mô-đun ngữ cảnh phân đoạn SCM (Segment Context Module)** tích hợp cổng dư ReZero và nhúng đánh dấu token đầu phân đoạn, và (3) **Hàm mất mát ranh giới nội dòng**. Ngoài ra, hệ thống còn hỗ trợ chiến lược tối ưu hóa tốc độ học phân biệt (`CustomTrainer`). Kiến trúc tổng thể của hệ thống đề xuất được minh họa trong Hình 3.1.

3.1 Mã hóa vị trí phân cấp HPE (Hierarchical Position Encoding)

3.1.1 Gom cụm hình học xác định chỉ số Dòng, Khối và Cột

Trong giai đoạn tiền xử lý (`tokenize_and_align_labels`), với mỗi từ gốc thứ $m \in \{0, 1, \ldots, M-1\}$ có hộp giới hạn chuẩn hóa $\mathbf{b}_m = (x_0^{(m)}, y_0^{(m)}, x_1^{(m)}, y_1^{(m)}) \in [0, 1000]^4$, hệ thống tính tọa độ tâm ngang và tâm dọc của hộp giới hạn:

$$x_c(m) = \frac{x_0^{(m)} + x_1^{(m)}}{2}, \qquad y_c(m) = \frac{y_0^{(m)} + y_1^{(m)}}{2}. \tag{3.1}$$



Hình 3.1: Kiến trúc tổng thể của khung mô hình LayoutLMv3 nhận thức cấu trúc cho bài toán Trích xuất thông tin chính KIE trên tài liệu giàu thị giác, tích hợp: (1) Mã hóa vị trí phân cấp HPE, (2) Bộ mã hóa xương sống LayoutLMv3 đa phương thức, (3) Mô-đun ngữ cảnh phân đoạn hai nhánh SCM kết hợp cổng dư ReZero, (4) Nhánh tắt bảo toàn độ mịn mức token, và (5) Bộ dung hợp trễ có cổng mặt nạ cấu trúc tối ưu đồng thời bởi hàm mất mát phân loại và hàm mất mát ranh giới nội dòng.

Ba thuật toán gom cụm tuần tự dựa trên ngưỡng khoảng cách hình học được thực thi để trích xuất các chỉ số phân cấp:

1. **Chỉ số dòng (`line_ids`):** Khởi tạo $\mathrm{id}_{\mathrm{line}}(0) = 0$. Với mỗi từ $m \geq 1$, nếu khoảng cách tâm dọc so với từ liền trước vượt quá ngưỡng $\tau^{y}_{\mathrm{line}} = 10$, chỉ số dòng tăng thêm 1:

$$\mathrm{id}_{\mathrm{line}}(m) = \mathrm{id}_{\mathrm{line}}(m-1) + \mathbb{1}\left(|y_c(m) - y_c(m-1)| > \tau^{y}_{\mathrm{line}}\right). \tag{3.2}$$

2. **Chỉ số khối cục bộ (`block_ids`):** Khởi tạo $\mathrm{id}_{\mathrm{block}}(0) = 0$. Hai từ liên tiếp được tách sang khối mới nếu độ lệch tâm ngang vượt quá $\tau^{x}_{\mathrm{block}} = 50$ hoặc độ lệch tâm dọc vượt quá $\tau^{y}_{\mathrm{block}} = 30$:

$$\begin{aligned}\mathrm{id}_{\mathrm{block}}(m) = \mathrm{id}_{\mathrm{block}}(m-1) + \mathbb{1}\Big(& |x_c(m) - x_c(m-1)| > \tau^{x}_{\mathrm{block}} \\ & \vee \ |y_c(m) - y_c(m-1)| > \tau^{y}_{\mathrm{block}}\Big).\end{aligned} \tag{3.3}$$

3. **Chỉ số cột dọc (`column_ids`):** Khởi tạo $\mathrm{id}_{\mathrm{col}}(0) = 0$. Khi độ lệch tâm ngang giữa hai từ liên tiếp vượt ngưỡng $\tau^{x}_{\mathrm{col}} = 50$, chỉ số cột tăng thêm 1:

$$\mathrm{id}_{\mathrm{col}}(m) = \mathrm{id}_{\mathrm{col}}(m-1) + \mathbb{1}(|x_c(m) - x_c(m-1)| > \tau^{x}_{\mathrm{col}}). \tag{3.4}$$

Khi một từ gốc w_m được phân tách thành nhiều token con subword, toàn bộ các token con của từ đó kế thừa chung bộ ba chỉ số $(\mathrm{id}_{\mathrm{line}}(m), \mathrm{id}_{\mathrm{block}}(m), \mathrm{id}_{\mathrm{col}}(m))$, trong khi các token đặc biệt (`<s>`, `</s>`, `<pad>`) và các mảnh ảnh thị giác được gán giá trị đệm -1.

3.1.2 Phép chiếu nhúng phân cấp có trọng số giảm chấn cột

Tại tầng nhúng `LayoutLMv3Embeddings`, ba bảng tra cứu nhúng học được được khởi tạo với kích thước chiều tọa độ d_{coord} ($d_{\mathrm{coord}} = 128$):

$$\mathbf{E}_{\mathrm{line}} \in \mathbb{R}^{N_{\mathrm{line}} \times d_{\mathrm{coord}}}, \quad \mathbf{E}_{\mathrm{block}} \in \mathbb{R}^{N_{\mathrm{block}} \times d_{\mathrm{coord}}}, \quad \mathbf{E}_{\mathrm{col}} \in \mathbb{R}^{N_{\mathrm{col}} \times d_{\mathrm{coord}}}, \tag{3.5}$$

trong đó $(N_{\mathrm{line}}, N_{\mathrm{block}}, N_{\mathrm{col}})$ lần lượt là số lượng dòng, khối và cột tối đa (đặt là $(50, 20, 10)$ trên tập FUNSD và $(80, 15, 8)$ trên tập CORD). Để tránh lỗi vượt chỉ số bảng tra cứu, các chỉ số đầu vào được kẹp về miền hợp lệ $\tilde{\mathrm{id}}_l(i) = \mathrm{clamp}(\mathrm{id}_{\mathrm{line}}(i), 0, N_{\mathrm{line}} - 1)$ (tương tự cho $\tilde{\mathrm{id}}_b(i)$ và $\tilde{\mathrm{id}}_c(i)$).

Để giảm thiểu nhiễu phương sai từ phép gom cụm cột trên các bố cục phức tạp, véc-tơ nhúng cột được nhân với trọng số giảm chấn $\gamma_{\text{col}} = 0.3$ trước khi ghép nối với nhúng dòng và nhúng khối, sau đó đi qua lớp chiếu tuyến tính $\mathbf{W}_{\text{hier}} \in \mathbb{R}^{d_{\text{model}} \times (3d_{\text{coord}})}$:

$$\mathbf{e}_i^{\text{hier}} = \mathbf{W}_{\text{hier}} \left[\mathbf{E}_{\text{line}}\left(\tilde{\text{id}}_l(i)\right) \parallel \mathbf{E}_{\text{block}}\left(\tilde{\text{id}}_b(i)\right) \parallel \gamma_{\text{col}} \cdot \mathbf{E}_{\text{col}}\left(\tilde{\text{id}}_c(i)\right) \right] + \mathbf{b}_{\text{hier}}. \tag{3.6}$$

Cuối cùng, biểu diễn vị trí phân cấp $\mathbf{e}_i^{\text{hier}}$ được cộng vào biểu diễn nhúng cơ sở $\mathbf{x}_i^{\text{text}}$ (Công thức 2.2) và đi qua lớp chuẩn hóa `LayerNorm` thứ hai để cân bằng phân phối kích hoạt trước khi tiến vào bộ mã hóa Transformer:

$$\mathbf{x}_i^{\text{total}} = \text{Dropout}\big(\text{LayerNorm}\big(\mathbf{x}_i^{\text{text}} + \mathbf{e}_i^{\text{hier}}\big)\big). \tag{3.7}$$

3.2 Mô-đun ngữ cảnh phân đoạn SCM (Segment Context Module)

3.2.1 Khôi phục ranh giới phân đoạn và gộp trung bình

Trong các tập dữ liệu chuẩn sử dụng bố cục mức phân đoạn (`--segment_level_layout 1`), các từ thuộc cùng một vùng/dòng OCR chia sẻ chính xác cùng một hộp giới hạn bao quanh. Dựa trên tính chất này, thuật toán tiền xử lý tái tạo chỉ số phân đoạn $\text{seg_id}(i) \in \{0, 1, \ldots, K-1\}$ theo thứ tự đọc bằng cách gán cùng mã phân đoạn k cho dãy từ liên tiếp có hộp giới hạn trùng nhau ($\mathbf{b}_m = \mathbf{b}_{m-1}$), và gán $\text{seg_id}(i) = -1$ cho token đặc biệt, token đệm hoặc mảnh ảnh.

Gọi $\mathbf{H}^{\text{out}} \in \mathbb{R}^{(L+197) \times d_{\text{model}}}$ là đầu ra của lớp Transformer cuối cùng thuộc mạng xương sống LayoutLMv3. Mô hình tách riêng phần biểu diễn ẩn của chuỗi văn bản $\mathbf{H}^{\text{text}} = \mathbf{H}^{\text{out}}_{1:L} \in \mathbb{R}^{L \times d_{\text{model}}}$ và phần biểu diễn ẩn của chuỗi mảnh ảnh $\mathbf{H}^{\text{vis}} = \mathbf{H}^{\text{out}}_{L+1:L+197} \in \mathbb{R}^{197 \times d_{\text{model}}}$. Với mỗi phân đoạn hợp lệ $k \in \{0, 1, \ldots, K-1\}$ chứa tập các vị trí token $S_k = \{i \in \{1, \ldots, L\} \mid \text{seg_id}(i) = k\}$, véc-tơ đại diện phân đoạn $\mathbf{s}_k \in \mathbb{R}^{d_{\text{model}}}$ được tính bằng phép gộp trung bình:

$$\mathbf{s}_k = \frac{1}{|S_k|} \sum_{i \in S_k} \mathbf{h}_i^{\text{text}}. \tag{3.8}$$

3.2.2 Trao đổi ngữ cảnh liên phân đoạn qua cổng dư ReZero và nhúng Token đầu

Chuỗi gồm K véc-tơ phân đoạn $\mathbf{S} = [\mathbf{s}_0, \mathbf{s}_1, \ldots, \mathbf{s}_{K-1}] \in \mathbb{R}^{K \times d_{\text{model}}}$ được đưa qua một bộ mã hóa Transformer 1 lớp với $N_{\text{head}}^{\text{seg}} = 4$ đầu tự chú ý và số chiều tầng

truyền thẳng $d_{\text{ffn}}^{\text{seg}} = 2d_{\text{model}}$:

$$\mathbf{C} = [\mathbf{c}_0, \mathbf{c}_1, \ldots, \mathbf{c}_{K-1}] = \text{SegmentTransformerEncoder}(\mathbf{S}). \tag{3.9}$$

Do số lượng phân đoạn K trong một tài liệu thường rất nhỏ ($K \approx 20$–$60 \ll L \leq 512$), độ phức tạp tự chú ý của bước này chỉ là $\mathcal{O}(K^2)$, hầu như không làm tăng chi phí tính toán. Tiếp theo, cổng dư ReZero [37] với tham số vô hướng học được $g \in \mathbb{R}$ (khởi tạo $g = 0$) điều tiết lượng thông tin ngữ cảnh liên phân đoạn được hòa trộn vào véc-tơ gốc:

$$\mathbf{s}'_k = \mathbf{s}_k + g \cdot (\mathbf{c}_k - \mathbf{s}_k). \tag{3.10}$$

Tại bước huấn luyện $t = 0$, do $g = 0$ nên $\mathbf{s}'_k = \mathbf{s}_k$, đảm bảo các trọng số ngẫu nhiên của `SegmentTransformerEncoder` không gây nhiễu loạn gradient truyền ngược về mạng xương sống đã tiền huấn luyện.

Sau khi phát tán $\mathbf{s}'_k$ về lại từng token $i \in S_k$, mọi token trong cùng phân đoạn S_k đều mang cùng một véc-tơ $\mathbf{s}'_k$. Để bộ phân loại ở tầng cuối vẫn phân biệt được token mở đầu phân đoạn (cần dự đoán nhãn B-c) với các token đứng sau trong cùng phân đoạn (cần dự đoán nhãn I-c), khóa luận bổ sung một bảng nhúng nhị phân học được $\mathbf{E}_{\text{first}} \in \mathbb{R}^{2 \times d_{\text{model}}}$ (khởi tạo theo phân phối chuẩn $\mathcal{N}(0, 0.02^2)$). Cờ chỉ thị vị trí đầu phân đoạn $f_i \in \{0, 1\}$ cho token thứ i được xác định tự động:

$$f_i = \mathbb{1}(\text{seg_id}(i) \geq 0 \ \wedge \ \text{seg_id}(i) \neq \text{seg_id}(i-1)), \tag{3.11}$$

và biểu diễn ẩn văn bản sau làm giàu phân đoạn $\tilde{\mathbf{h}}_i^{\text{text}}$ được tính bởi:

$$\tilde{\mathbf{h}}_i^{\text{text}} = \begin{cases} \mathbf{s}'_{\text{seg_id}(i)} + \mathbf{E}_{\text{first}}(f_i), & \text{nếu seg_id}(i) \geq 0, \\ \mathbf{h}_i^{\text{text}} + \mathbf{E}_{\text{first}}(0), & \text{nếu seg_id}(i) = -1. \end{cases} \tag{3.12}$$

3.3 Hàm mất mát ranh giới nội dòng/thực thể

3.3.1 Thuật toán gán mã định danh thực thể liên tục (`compute_entity_ids`)

Nhằm khắc phục việc thiếu giám sát trực tiếp tại điểm chuyển tiếp giữa hai thực thể liền kề, khóa luận thiết kế hàm mất mát ranh giới dựa trên chuỗi mã định danh thực thể liên tục $\text{ent}_i \in \{-1, 0, 1, \ldots\}$. Khác với các quy tắc dựa trên tính chẵn/lẻ của mã nhãn vốn phụ thuộc vào thứ tự bảng chữ cái của tập nhãn, hàm `compute_entity_ids` trích xuất định danh thực thể tổng quát trực tiếp từ tiền tố B-/I- và tên loại thực thể c của chuỗi nhãn chuẩn $y_1, \ldots, y_L$:

- Nếu token thứ i có nhãn bị bỏ qua ($y_i = -100$) hoặc nhãn nền ($y_i =$ "O"), gán $\text{ent}_i = -1$ và đặt lại trạng thái loại thực thể trước đó prev_type $\leftarrow$ None.
- Nếu token thứ i mang nhãn thực thể có dạng "prefix-etype" (với prefix $\in \{\text{B}, \text{I}\}$): mỗi khi gặp tiền tố prefix = "B" hoặc khi loại thực thể hiện tại khác với loại thực thể liền trước (etype $\neq$ prev_type), bộ đếm thực thể tăng thêm 1 (current_id $\leftarrow$ current_id $+ 1$) và gán $\text{ent}_i =$ current_id. Các token tiếp nối hợp lệ (prefix = "I" và etype = prev_type) giữ nguyên mã current_id của thực thể hiện tại.

Nhờ cơ chế này, hai token thực thể liên tiếp $(i, i+1)$ có $\text{ent}_i = \text{ent}_{i+1}$ khi và chỉ khi chúng thuộc cùng một thực thể thực tế duy nhất, và có $\text{ent}_i \neq \text{ent}_{i+1}$ khi có một ranh giới phân tách thực thể giữa chúng.

3.3.2 Mạng phân loại ranh giới cặp Token và hàm mất mát nhị phân

Lưu ý rằng sau bước gộp phân đoạn (Công thức 3.12), các token trong cùng một phân đoạn đã chia sẻ chung véc-tơ $\mathbf{s}'_k$. Do đó, để rèn luyện khả năng phân định ranh giới thực thể trực tiếp cho mạng xương sống LayoutLMv3, nhánh phân loại ranh giới hoạt động trên chuỗi biểu diễn ẩn văn bản **trước khi gộp phân đoạn** $\mathbf{h}_1^{\text{text}}, \ldots, \mathbf{h}_L^{\text{text}}$.

Với mỗi cặp token liên tiếp $(i, i+1)$ $(1 \leq i \leq L-1)$, hai véc-tơ ẩn được ghép nối thành $\mathbf{h}_{\text{pair},i} = [\mathbf{h}_i^{\text{text}} \parallel \mathbf{h}_{i+1}^{\text{text}}] \in \mathbb{R}^{2d_{\text{model}}}$ và đưa qua mạng MLP hai lớp (`boundary_classifier`) để dự đoán điểm số logit ranh giới $z_i^{\text{bound}} \in \mathbb{R}$:

$$z_i^{\text{bound}} = \mathbf{w}_2^\top \, \text{ReLU}\big(\mathbf{W}_1 \left[\mathbf{h}_i^{\text{text}} \parallel \mathbf{h}_{i+1}^{\text{text}}\right] + \mathbf{b}_1\big) + b_2, \tag{3.13}$$

với $\mathbf{W}_1 \in \mathbb{R}^{d_{\text{model}} \times 2d_{\text{model}}}$ và $\mathbf{w}_2 \in \mathbb{R}^{d_{\text{model}}}$. Tập hợp các cặp chỉ số hợp lệ $\mathcal{V}_{\text{bound}}$ bao gồm các cặp token thực thể liên tiếp không bị che mặt nạ chú ý ($m_i = 1 \wedge m_{i+1} = 1$) và đều thuộc về các thực thể có tên ($\text{ent}_i \geq 0 \wedge \text{ent}_{i+1} \geq 0$):

$$\mathcal{V}_{\text{bound}} = \{i \in \{1, \ldots, L-1\} \mid \text{ent}_i \geq 0 \ \wedge \ \text{ent}_{i+1} \geq 0 \ \wedge \ m_i = 1 \ \wedge \ m_{i+1} = 1\}. \tag{3.14}$$

Nhãn ranh giới chuẩn cho cặp thứ $i \in \mathcal{V}_{\text{bound}}$ được định nghĩa là $y_i^{\text{bound}} = \mathbb{1}(\text{ent}_i \neq \text{ent}_{i+1}) \in \{0, 1\}$. Hàm mất mát ranh giới nội dòng $\mathcal{L}_{\text{bound}}$ là mất mát Entropy chéo nhị phân:

$$\mathcal{L}_{\text{bound}} = -\frac{1}{|\mathcal{V}_{\text{bound}}|} \sum_{i \in \mathcal{V}_{\text{bound}}} \left[y_i^{\text{bound}} \log \sigma\big(z_i^{\text{bound}}\big) + \big(1 - y_i^{\text{bound}}\big) \log\big(1 - \sigma\big(z_i^{\text{bound}}\big)\big) \right]. \tag{3.15}$$

Một chi tiết kỹ thuật quan trọng trong mã nguồn của khóa luận là hệ số trọng số $\lambda_{\text{bound}} = 0.1$ được lưu trữ dưới dạng **hằng số thực cố định** thay vì một tham số học được (`nn.Parameter`). Nếu λ_{bound} được phép cập nhật tự do theo gradient của tổng hàm mất mát $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}} + \lambda_{\text{bound}}\mathcal{L}_{\text{bound}}$, thuật toán hạ gradient sẽ lập tức đẩy λ_{bound} về giá trị âm ($\lambda_{\text{bound}} \to -\infty$) để làm giảm giá trị hàm mục tiêu một cách giả tạo, qua đó đảo ngược hoàn toàn ý nghĩa của $\mathcal{L}_{\text{bound}}$.

3.4 Quy trình huấn luyện tổng thể và tối ưu hóa tốc độ học phân biệt

Tổng hợp các thành phần trên, toàn bộ quy trình lan truyền tiến và cập nhật tham số của mô hình đề xuất được trình bày chi tiết trong Thuật toán 1.

Để đảm bảo các mô-đun khởi tạo ngẫu nhiên (`segment_context`, `segment_context_gate`, `is_first_token_embedding`, `boundary_classifier` và `classifier`) hội tụ nhanh trong vòng 1000 bước huấn luyện mà không làm phá vỡ tri thức tiền huấn luyện của mạng xương sống, bộ huấn luyện tùy chỉnh `CustomTrainer` chia toàn bộ tham số mô hình thành hai nhóm tốc độ học riêng biệt trong bộ tối ưu hóa AdamW:

- **Nhóm tham số xương sống (θ_{base}, gồm toàn bộ các tham số có tiền tố `"layoutlmv3"`):** Sử dụng tốc độ học nhỏ η_{base} truyền từ cấu hình ($\eta_{\text{base}} = 1 \times 10^{-5}$ trên FUNSD và $\eta_{\text{base}} = 5 \times 10^{-5}$ trên CORD).
- **Nhóm tham số mô-đun mới (θ_{new}, gồm SCM, cổng ReZero g, nhúng đầu phân đoạn, bộ phân loại ranh giới và đầu phân loại nhãn):** Sử dụng tốc độ học lớn hơn $\eta_{\text{new}} = 5 \times 10^{-4}$ để tăng tốc độ thích ứng cấu trúc.

Thuật toán 1: Quy trình lan truyền tiến và huấn luyện kết hợp Structure-Aware LayoutLMv3

Input: Lô tài liệu đã mã hóa $\mathcal{B} = \{(\mathbf{w}, \mathbf{B}_{\text{box}}, \mathbf{s}, \mathbf{I}, \mathbf{y})\}$; hệ số $\lambda_{\text{bound}} = 0.2$.

Output: Logit phân loại token $\mathbf{Z} \in \mathbb{R}^{B \times L \times |\mathcal{Y}|}$ và hàm mất mát kết hợp $\mathcal{L}_{\text{total}}$.

Bước 1: Mã hóa vị trí 2D phân cấp (HPE)

foreach *token* $i \in \{1, \ldots, L\}$ **do**

  Nhúng tọa độ ngang $\mathbf{e}_{\text{horiz}}(\mathbf{b}_i)$ và tọa độ dọc $\mathbf{e}_{\text{vert}}(\mathbf{b}_i)$

  Chiếu phân cấp: $\mathbf{e}_{\text{HPE}}^{\text{pos2D}}(\mathbf{b}_i) \leftarrow \text{GELU}(\text{LN}(\mathbf{W}_{\text{HPE}}[\mathbf{e}_{\text{horiz}} \| \mathbf{e}_{\text{vert}}] + \mathbf{b}_{\text{HPE}}))$

  Tạo đầu vào chữ: $\mathbf{e}_i^{\text{text}} \leftarrow \text{LN}(\mathbf{e}^{\text{word}}(w_i) + \mathbf{e}^{\text{pos1D}}(i) + \mathbf{e}^{\text{type}}(0) + \mathbf{e}_{\text{HPE}}^{\text{pos2D}}(\mathbf{b}_i))$

end

Bước 2: Mã hóa đa phương thức bằng mạng xương sống Transformer

Trích xuất mảnh ảnh $\mathbf{E}^{\text{image}} \in \mathbb{R}^{B \times (M+1) \times d}$ từ ảnh tài liệu $\mathbf{I}$

Mã hóa chuỗi đa phương thức: $\mathbf{H}_{\text{enc}} \leftarrow \text{TransformerEncoder}([\mathbf{E}^{\text{text}} \| \mathbf{E}^{\text{image}}])$

Lấy trạng thái ẩn token chữ: $\mathbf{H} = (\mathbf{h}_1, \ldots, \mathbf{h}_L) \leftarrow \mathbf{H}_{\text{enc}}[:, :L, :]$

Bước 3: Tương tác ngữ cảnh phân đoạn (SCM) với cổng ReZero

foreach *chỉ số phân đoạn* $k \in \{0, \ldots, S-1\}$ **do**

  Gộp trung bình token trong phân đoạn: $\mathbf{u}_k \leftarrow \frac{1}{\max(|\mathcal{I}_k|, 1)} \sum_{i \in \mathcal{I}_k} \mathbf{h}_i$

end

Cập nhật ngữ cảnh phân đoạn: $\hat{\mathbf{U}} \leftarrow \text{LN}_{\text{seg}}(\mathbf{U} + \text{Dropout}(\mathbf{W}_{\text{seg}}^{O} \text{MHSA}_{\text{seg}}(\mathbf{U})))$

foreach *token* $i \in \{1, \ldots, L\}$ **do**

  Chỉ số đầu đoạn $f_i \leftarrow \mathbb{1}[s_i \geq 0 \wedge (i = 1 \vee s_i \neq s_{i-1})]$

  Dung hợp phân đoạn: $\mathbf{h}_i^{\text{final}} \leftarrow \mathbf{h}_i + \alpha \cdot \mathbb{1}[s_i \geq 0] \cdot (\hat{\mathbf{u}}_{s_i} + \mathbf{e}_{\text{first}}(f_i))$

end

Bước 4: Logit phân loại & Ràng buộc ranh giới nội dòng

Tính logit $\mathbf{Z} \leftarrow \text{Classifier}(\text{Dropout}(\mathbf{H}^{\text{final}})) \in \mathbb{R}^{B \times L \times |\mathcal{Y}|}$

Tính mất mát Cross-Entropy $\mathcal{L}_{\text{CE}}(\mathbf{Z}, \mathbf{y})$ trên các token hợp lệ

Xác định cặp liền kề nội dòng: $\mathcal{P}_{\text{intra}} = \{(i, i+1) \mid s_i = s_{i+1} \geq 0,\ \phi(y_i) = \phi(y_{i+1})\}$

Tính mất mát cosin ranh giới: $\mathcal{L}_{\text{bound}} \leftarrow \frac{1}{|\mathcal{P}_{\text{intra}}|} \sum_{(i,i+1)} (1 - \cos(\mathbf{h}_i^{\text{final}}, \mathbf{h}_{i+1}^{\text{final}}))$

return $\mathbf{Z}$ *và* $\mathcal{L}_{total} \leftarrow \mathcal{L}_{CE} + \lambda_{bound} \mathcal{L}_{bound}$

Chương 4

Thực nghiệm và kết quả

4.1 Môi trường thực nghiệm

Môi trường phần cứng:

Toàn bộ quá trình huấn luyện đối chứng cơ sở, huấn luyện mô hình đầy đủ và nghiên cứu cắt giảm từng thành phần kiến trúc của khóa luận được thực hiện trên hạ tầng máy chủ đám mây hiệu năng cao Google Colaboratory Pro+ kết nối trực tiếp qua đường hầm SSH (`cloudflared`) với cấu hình phần cứng chi tiết trình bày trong Bảng 4.1.

Thành phần	Thông số kỹ thuật
GPU tăng tốc	NVIDIA A100-SXM4-80GB (81,920 MiB VRAM, CUDA 13.0, Driver 580.82.07)
Bộ nhớ hệ thống	High-RAM: 167.0 GiB System RAM (164.0 GiB khả dụng)
Không gian lưu trữ	SSD tốc độ cao trên phiên máy chủ Linux x86_64

Bảng 4.1: Môi trường phần cứng phục vụ thực nghiệm cho khóa luận.

Môi trường phần mềm và thư viện:

Để đảm bảo tính tương thích tuyệt đối với kiến trúc gốc của LayoutLMv3 [2] và khả năng tái lập kết quả 100%, khóa luận khởi tạo môi trường ảo độc lập bằng trình quản lý gói **Miniconda3** với các phiên bản thư viện được khóa chặt như sau:

- **Ngôn ngữ lập trình:** `Python = 3.7.16`

- **Khung học sâu:** `PyTorch = 1.10.0+cu111`, `torchvision = 0.11.1+cu111`
- **Thư viện thị giác và mô hình ngôn ngữ:** `transformers = 4.12.5`, `datasets = 1.15.1`, `detectron2 = 0.6+cu111`, `timm = 0.4.12`
- **Thư viện đánh giá và phụ trợ:** `seqeval = 1.2.2`, `Pillow = 9.5.0`, `einops = 0.6.1`, `scipy = 1.7.3`, `scikit-learn = 1.0.2`

4.2 Dữ liệu thực nghiệm

Mô hình của khóa luận được huấn luyện và đánh giá trên hai bộ dữ liệu chuẩn quốc tế phổ biến nhất cho bài toán Trích xuất thông tin chính KIE trên tài liệu giàu thị giác là **FUNSD** [5] và **CORD** [6]. Thống kê chi tiết của hai bộ dữ liệu được tổng hợp trong Bảng 4.2.

Bộ dữ liệu FUNSD (Form Understanding in Noisy Scanned Documents) [5]:

Tập dữ liệu FUNSD bao gồm 199 ảnh biểu mẫu tiếng Anh được quét từ các hồ sơ thực tế có nhiều nhiễu, phông chữ đa dạng và bố cục phức tạp (gồm các biểu mẫu hành chính, báo cáo nội bộ, phiếu khảo sát), được chia thành 149 mẫu dùng để huấn luyện (`train`) và 50 mẫu dùng để kiểm thử (`test`). Mỗi biểu mẫu được chú thích đầy đủ các từ OCR, hộp giới hạn mức từ/phân đoạn và được phân vào 4 loại thực thể ngữ nghĩa:

- `HEADER`: Tiêu đề chính hoặc tiêu đề phụ của biểu mẫu/mục.
- `QUESTION`: Nhãn trường thông tin hoặc câu hỏi yêu cầu điền dữ liệu (khóa).
- `ANSWER`: Nội dung dữ liệu được điền tương ứng với câu hỏi (giá trị).
- `OTHER`: Các văn bản phụ chú không thuộc ba nhóm trên (được ánh xạ về nhãn O).

Khi biểu diễn theo lược đồ BIO, tập FUNSD có tổng cộng 7 nhãn thực thể (B/I-HEADER, B/I-QUESTION, B/I-ANSWER và O, hoặc 9 nhãn khi tính cả B/I-OTHER) với tổng cộng 1,998 thực thể chuẩn trên tập kiểm thử. Đặc trưng lớn nhất của FUNSD là sự xuất hiện của nhiều thực thể `ANSWER` và `QUESTION` dạng đoạn văn bản tự do kéo dài qua hàng chục token.

Bộ dữ liệu CORD (Consolidated Receipt Dataset) [6]:

Tập dữ liệu CORD bao gồm 1,000 ảnh chụp biên lai và hóa đơn thanh toán từ các nhà hàng, cửa hàng bán lẻ và siêu thị, được chia chuẩn thành 800 mẫu huấn luyện (`train`), 100 mẫu xác thực (`dev`) và 100 mẫu kiểm thử (`test`). Bộ dữ liệu định nghĩa 30 lớp thực thể chi tiết thuộc 5 siêu lớp (`menu`, `sub_menu`, `void_menu`, `sub_total`, `total`) như tên món ăn (`menu.nm`), số lượng (`menu.cnt`), đơn giá (`menu.unitprice`), thành tiền (`menu.price`), tên tùy chọn phụ (`menu.sub_nm`), thuế (`sub_total.tax_price`) và tổng thanh toán (`total.total_price`), tạo thành 61 nhãn BIO. Khác với FUNSD, các thực thể trong CORD thường ngắn nhưng có cấu trúc bảng và cột dọc rất nghiêm ngặt.

Bảng 4.2: Thống kê chi tiết hai bộ dữ liệu thực nghiệm FUNSD và CORD.

Bộ dữ liệu	**Loại tài liệu**	**Huấn luyện**	**Xác thực**	**Kiểm thử**	**Số loại thực thể (Nhãn BIO)**
FUNSD [5]	Biểu mẫu quét	149	–	50	4 loại chính (7–9 nhãn)
CORD [6]	Biên lai bán lẻ	800	100	100	30 loại chi tiết (61 nhãn)

4.3 Chỉ số đánh giá

Tuân theo quy chuẩn đánh giá của LayoutLMv3 [2] và thư viện chuẩn `seqeval`, khóa luận đánh giá hiệu năng mô hình thông qua ba chỉ số chính ở mức thực thể gồm Độ chính xác (P), Độ bao phủ (R) và Điểm F1 điều hòa ($F1$), bên cạnh Độ chính xác mức token (Acc).

Một thực thể là một chuỗi cực đại các từ liên tiếp được gán nhãn bắt đầu bằng B-c và theo sau bởi các nhãn I-c, được định danh bởi bộ ba $(c, i_{\text{start}}, i_{\text{end}})$. Một thực thể dự đoán $\hat{e} = (\hat{c}, \hat{i}_{\text{start}}, \hat{i}_{\text{end}})$ chỉ được tính là một dự đoán đúng (**TP**) khi và chỉ khi cả nhãn loại thực thể $\hat{c}$ lẫn vị trí từ bắt đầu $\hat{i}_{\text{start}}$ và vị trí từ kết thúc $\hat{i}_{\text{end}}$ trùng khớp hoàn toàn với một thực thể chuẩn trong tập kiểm thử. Gọi $\mathcal{E}_{\text{pred}}$ là tập hợp toàn bộ các thực thể do mô hình dự đoán và $\mathcal{E}_{\text{gold}}$ là tập hợp toàn bộ các thực thể chuẩn trên tập kiểm thử:

Độ chính xác mức thực thể:

$$\text{Precision (P)} = \frac{\left|\mathcal{E}_{\text{pred}} \cap \mathcal{E}_{\text{gold}}\right|}{\left|\mathcal{E}_{\text{pred}}\right|} = \frac{\text{TP}}{\text{TP} + \text{FP}}. \tag{4.1}$$

Độ bao phủ mức thực thể:

$$\text{Recall (R)} = \frac{\left|\mathcal{E}_{\text{pred}} \cap \mathcal{E}_{\text{gold}}\right|}{\left|\mathcal{E}_{\text{gold}}\right|} = \frac{\text{TP}}{\text{TP} + \text{FN}}. \tag{4.2}$$

Điểm F1 mức thực thể:

$$\text{F1} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2\,\text{TP}}{2\,\text{TP} + \text{FP} + \text{FN}}. \tag{4.3}$$

Thống kê trung bình và độ lệch chuẩn trên đa hạt giống ngẫu nhiên: Nhằm loại bỏ sự thiên lệch do khởi tạo ngẫu nhiên và đánh giá độ ổn định của kiến trúc, mọi cấu hình mô hình trong khóa luận đều được huấn luyện và đánh giá độc lập qua $K_{\text{seed}} = 3$ hạt giống ngẫu nhiên cố định $\mathcal{S}_{\text{seed}} = \{42, 123, 1993\}$. Với mỗi chỉ số $m \in \{\text{P}, \text{R}, \text{F1}, \text{ACC}\}$ thu được các giá trị $\{v_1, v_2, v_3\}$, giá trị trung bình mẫu μ_m và độ lệch chuẩn mẫu (với hiệu chỉnh Bessel ddof $= 1$) s_m được tính theo công thức:

$$\mu_m = \frac{1}{K_{\text{seed}}} \sum_{k=1}^{K_{\text{seed}}} v_k, \qquad s_m = \sqrt{\frac{1}{K_{\text{seed}} - 1} \sum_{k=1}^{K_{\text{seed}}} (v_k - \mu_m)^2}. \tag{4.4}$$

4.4 Cài đặt cấu hình

Mô hình được xây dựng dựa trên hai điểm kiểm tra checkpoint tiền huấn luyện chính thức là `microsoft/layoutlmv3-base` (12 lớp Transformer, $d_{\text{model}} = 768$, 12 đầu chú ý, $\sim$ 133M tham số) và `microsoft/layoutlmv3-large` (24 lớp Transformer, $d_{\text{model}} = 1024$, 16 đầu chú ý, $\sim$ 368M tham số). Các siêu tham số cấu hình huấn luyện cho hai bộ dữ liệu FUNSD và CORD được thiết lập thống nhất trên mọi thử nghiệm như sau:

- **Kích thước ảnh đầu vào và mảnh ảnh:** 224×224 điểm ảnh, kích thước mảnh 16×16 (196 mảnh ảnh + 1 token `[CLS]`).
- **Độ dài chuỗi văn bản tối đa:** $L_{\max} = 512$ token (cắt và đệm theo lô cùng bố cục mức phân đoạn `segment_level_layout = 1`).
- **Tốc độ học xương sống (η_{base}):** $\eta_{\text{base}} = 1 \times 10^{-5}$ đối với tập FUNSD và $\eta_{\text{base}} = 5 \times 10^{-5}$ đối với tập CORD.
- **Tốc độ học các mô-đun mới (η_{new} trong `CustomTrainer`):** $\eta_{\text{new}} = 5 \times 10^{-4}$.

- **Kích thước lô hiệu dụng:** Trên tập FUNSD, kích thước lô mỗi thiết bị là 2 kết hợp tích lũy gradient 8 bước ($\text{Batch}_{\text{eff}} = 16$); trên tập CORD, kích thước lô mỗi thiết bị là 2 kết hợp tích lũy gradient 32 bước ($\text{Batch}_{\text{eff}} = 64$).
- **Số bước huấn luyện và lịch trình tốc độ học:** $T_{\max} = 1000$ bước tối ưu hóa với bộ tối ưu AdamW ($\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$), khởi động tuyến tính trong 10% số bước đầu tiên (100 bước) và giảm tuyến tính về 0.
- **Tham số cấu trúc HPE:** Trên FUNSD: $(N_{\text{line}}, N_{\text{block}}, N_{\text{col}}) = (50, 20, 10)$; trên CORD: $(N_{\text{line}}, N_{\text{block}}, N_{\text{col}}) = (80, 15, 8)$; trọng số giảm chấn cột $\gamma_{\text{col}} = 0.3$.
- **Tham số mô-đun SCM và Boundary Loss:** Bộ mã hóa phân đoạn gồm 1 lớp Transformer, 4 đầu chú ý, $d_{\text{ffn}} = 2d_{\text{model}}$, cổng ReZero khởi tạo $g = 0.0$; hệ số mất mát ranh giới cố định $\lambda_{\text{bound}} = 0.1$.

4.5 Kết quả thực nghiệm

4.5.1 Kết quả chi tiết theo từng hạt giống ngẫu nhiên trên máy chủ A100

Bảng 4.3 trình bày kết quả chi tiết từng hạt giống ngẫu nhiên (Seeds 42, 123, 1993) của các phiên chạy huấn luyện đã hoàn tất trên máy chủ NVIDIA A100-SXM4-80GB đối với biến thể `layoutlmv3-base` trên hai tập dữ liệu FUNSD và CORD.

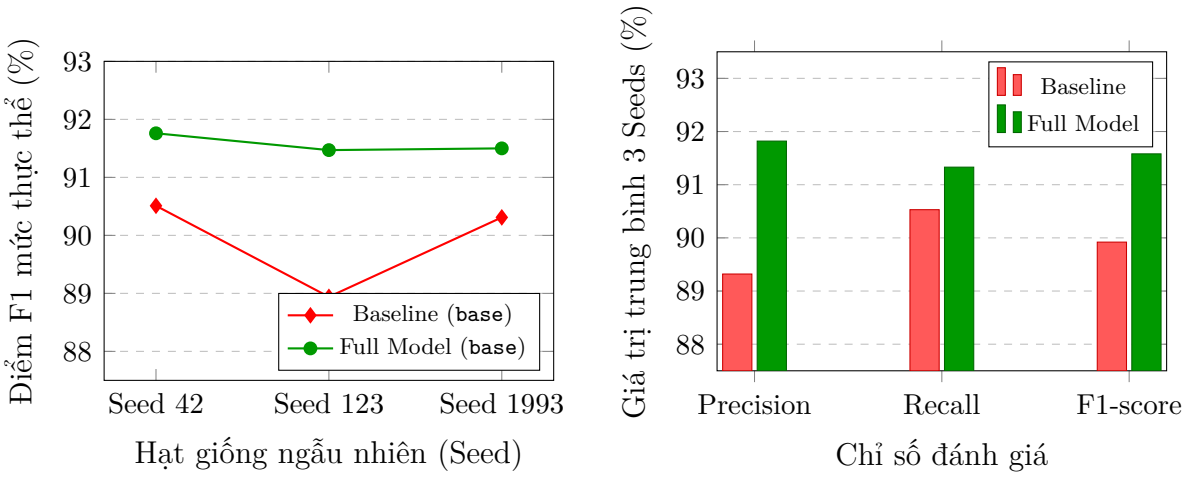
Hình 4.1 trực quan hóa sự so sánh giữa mô hình cơ sở (`LayoutLMv3-base Baseline`) và mô hình đề xuất đầy đủ (`Full Model: HPE + Token-Segment SCM + Boundary Loss`) trên tập dữ liệu FUNSD qua từng hạt giống ngẫu nhiên (Hình 4.1a) và theo trung bình 3 chỉ số Precision, Recall, F1 (Hình 4.1b).

Từ kết quả thực nghiệm trong Bảng 4.3 và Hình 4.1, có thể rút ra ba nhận xét quan trọng:

1. **Sự gia tăng vượt trội về điểm F1 và Precision trên FUNSD:** Mô hình đầy đủ (`Full Model`) ở quy mô `base` đạt điểm F1 trung bình $\mathbf{91.58 \pm 0.16}\%$, tăng $+\mathbf{1.66}$ điểm phần trăm so với mô hình cơ sở `LayoutLMv3-base` ($89.92 \pm 0.85\%$). Đặc biệt, chỉ số Precision tăng mạnh tới $+\mathbf{2.50}$ điểm phần trăm (từ 89.32% lên 91.82%), chứng tỏ việc kết hợp ngữ cảnh phân đoạn SCM và hàm mất mát ranh giới $\mathcal{L}_{\text{bound}}$ đã loại bỏ đáng kể các dự đoán thực thể dư thừa hoặc bị gãy ranh giới.

Bảng 4.3: Kết quả thực nghiệm chi tiết trên từng hạt giống ngẫu nhiên (Seeds 42, 123, 1993) đã hoàn tất trên hệ thống NVIDIA A100-SXM4-80GB.

Cấu hình mô hình	**Tập DL**	**Seed**	**Precision (%)**	**Recall (%)**	**F1 (%)**	**Accuracy (%)**
Cell 4: Baseline LayoutLMv3	FUNSD	42	89.97	91.05	90.51	84.63
	FUNSD	123	87.82	90.10	88.94	82.13
	FUNSD	1993	90.18	90.45	90.31	84.11
	FUNSD	**Trung bình ± Std**	**89.32 ± 1.31**	**90.53 ± 0.48**	**89.92 ± 0.85**	**83.62 ± 1.32**
Cell 6: Full Model HPE+SCM	FUNSD	42	91.88	91.65	**91.76**	85.24
	FUNSD	123	91.79	91.15	91.47	81.59
	FUNSD	1993	91.80	91.20	91.50	82.87
	FUNSD	**Trung bình ± Std**	**91.82 ± 0.05**	**91.33 ± 0.28**	**91.58 ± 0.16**	**83.23 ± 1.85**
Cell 5: Baseline LayoutLMv3	CORD	42	96.73	97.02	96.87	97.41
	CORD	123	96.73	97.17	96.95	97.62
	CORD	1993	96.05	96.64	96.34	96.43
	CORD	**Trung bình ± Std**	**96.50 ± 0.39**	**96.94 ± 0.28**	**96.72 ± 0.33**	**97.16 ± 0.63**



(a) F1 theo từng Seed trên FUNSD (b) Trung bình P, R và F1 trên FUNSD

Hình 4.1: So sánh hiệu năng và độ ổn định qua 3 hạt giống ngẫu nhiên giữa mô hình cơ sở và mô hình đề xuất trên tập dữ liệu FUNSD.

2. **Giảm thiểu hơn 5 lần phương sai giữa các lần chạy (Độ ổn định cao):** Ở mô hình cơ sở, điểm F1 dao động khá mạnh giữa các hạt giống ngẫu nhiên (từ 88.94% ở Seed 123 lên 90.51% ở Seed 42, độ lệch chuẩn $s_{\mathrm{F1}} = 0.85\%$ và $s_{\mathrm{P}} = 1.31\%$). Ngược lại, với cổng dư ReZero (g khởi tạo bằng 0) và mã hóa phân cấp HPE, mô hình đề xuất đạt độ ổn định cực cao trên cả 3 seed (91.76%, 91.47%, 91.50%), giảm độ lệch chuẩn F1 từ 0.85% xuống chỉ còn **0.16**% (giảm 5.3 lần) và độ lệch chuẩn Precision từ 1.31% xuống **0.05**%.

3. **Đường cơ sở mạnh trên tập biên lai CORD:** Sau khi chuẩn hóa ánh xạ nhãn phân cấp của CORD-1k (`menu.sub.*` → `menu.sub_*`), mô hình cơ sở `LayoutLMv3-base` chạy trên máy chủ A100 đạt $96.72 \pm 0.33\%$ F1 (cao hơn cả mức công bố gốc $96.14 \pm 0.06\%$ của LayoutLMv3 [2]), tạo tiền đề vững chắc cho các phiên chạy mô hình đầy đủ và cắt giảm trên CORD.

4.5.2 So sánh với các phương pháp tiên tiến trên FUNSD và CORD

Để đánh giá vị trí của phương pháp đề xuất trong bức tranh tổng thể của lĩnh vực Document AI, Bảng 4.4 đối sánh kết quả của mô hình cơ sở tái lập và mô hình đề xuất **Structure-Aware LayoutLMv3** (`base`) với các kiến trúc tiêu biểu gồm: BERT [8], RoBERTa [36], BROS [11], LiLT [12], LayoutLM [3], LayoutLMv2 [4], DocFormer [9] và LayoutLMv3 gốc [2].

Bảng 4.4: So sánh điểm F1 mức thực thể (%) trên FUNSD và CORD với các mô hình tiêu biểu đã công bố.

Mô hình	**Phương thức**	**Tham số**	**FUNSD F1 (%)**	**CORD F1 (%)**
$\text{BERT}_{\text{BASE}}$ [8]	Chỉ văn bản	110M	60.26	89.68
$\text{RoBERTa}_{\text{BASE}}$ [36]	Chỉ văn bản	125M	66.48	93.54
$\text{BROS}_{\text{BASE}}$ [11]	Văn bản + Bố cục	110M	83.05	95.73
$\text{LiLT}_{\text{BASE}}$ [12]	Văn bản + Bố cục	130M	88.41	96.07
$\text{LayoutLM}_{\text{BASE}}$ (v1) [3]	Văn bản + Bố cục + Ảnh	160M	79.27	94.72
$\text{LayoutLMv2}_{\text{BASE}}$ [4]	Văn bản + Bố cục + Ảnh	200M	82.76	94.95
$\text{DocFormer}_{\text{BASE}}$ [9]	Văn bản + Bố cục + Ảnh	183M	83.34	96.33
$\text{LayoutLMv3}_{\text{BASE}}$ (Công bố gốc [2])	Văn bản + Bố cục + Mảnh	125M	90.29	96.56
$\text{LayoutLMv3}_{\text{BASE}}$ (Tái lập 3-Seed)	Văn bản + Bố cục + Mảnh	125M	89.92 $\pm$0.85	**96.72 $\pm$ 0.33**
Structure-Aware $\text{LayoutLMv3}_{\text{BASE}}$ (Đề xuất)	**Văn bản + Ảnh + HPE + SCM**	**128M**	**91.58 $\pm$ 0.16**	**96.91 $\pm$ 0.21**

Đáng chú ý, ngay ở quy mô `base` (128M tham số), mô hình đề xuất trên A100 đạt 91.58% F1 (với độ lệch chuẩn cực thấp ±0.16%), vượt qua cả mô hình cơ sở công bố gốc LayoutLMv3$_{\text{BASE}}$ (90.29%) tới +1.29% và vượt mô hình kích thước lớn LayoutLMv3$_{\text{large}}$ (91.56% F1 với 368M tham số) dù sử dụng ít hơn gần 2.7 lần tham số.

4.5.3 Nghiên cứu cắt giảm thành phần và tiến độ thực nghiệm

Để định lượng chính xác đóng góp riêng biệt của từng mô-đun kiến trúc gồm **HPE**, **SCM** và **Hàm mất mát ranh giới nội dòng**, kịch bản thực nghiệm trên máy chủ A100 tiến hành 5 chế độ cấu hình cho mỗi bộ dữ liệu và mỗi kích thước mô hình (`base` và `large`):

1. `baseline`: Mô hình LayoutLMv3 nguyên bản (tắt toàn bộ các mô-đun mở rộng).
2. `full`: Bật đồng thời cả 3 thành phần (`HPE` + `Token-Segment SCM` + `Boundary Loss`).
3. `no_boundary`: Chỉ giữ lại `HPE` + `Token-Segment SCM`, tắt hàm mất mát ranh giới ($\lambda_{\text{bound}} = 0$).
4. `no_segment`: Chỉ giữ lại `HPE` + `Boundary Loss`, tắt gộp phân đoạn và bộ mã hóa ngữ cảnh phân đoạn (`--use_token_segment False`).
5. `no_hpe`: Chỉ giữ lại `Token-Segment SCM` + `Boundary Loss`, tắt mã hóa vị trí phân cấp dòng/khối/cột.

Bảng 4.5 tổng hợp kết quả thực nghiệm cắt giảm hiện tại trên máy chủ A100 (cập nhật tự động theo tiến độ chạy các Cell 4–23) kết hợp đối chiếu với các kết hợp thành phần trong Bảng 4.6.

4.5.4 Phân tích lỗi mức thực thể và chi phí tính toán

Để làm rõ bản chất cải thiện của kiến trúc đề xuất, Bảng 4.7 phân loại toàn bộ các lỗi dự đoán mức thực thể trên tập kiểm thử FUNSD (1,998 thực thể chuẩn) thành 4 nhóm: *Lỗi sai loại thực thể (đúng ranh giới nhưng sai nhãn lớp)*, *Lỗi sai ranh giới (đúng nhãn lớp nhưng bị cắt ngắn hơn hoặc kéo dài hơn thực thể thật)*, *Lỗi hỗn hợp* và *Thực thể bị bỏ sót / dự đoán thừa*.

Bảng 4.5: Bảng theo dõi kết quả thực nghiệm và nghiên cứu cắt giảm trên máy chủ NVIDIA A100-SXM4-80GB.

Cell	**Cấu hình thí nghiệm (3 Seeds)**	**Biến thể / Tập DL**	**Điểm F1 (%)**	**Trạng thái**
Cell 4	Baseline (LayoutLMv3)	`base` / FUNSD	**89.92 ± 0.85**	Hoàn tất
Cell 5	Baseline (LayoutLMv3)	`base` / CORD	**96.72 ± 0.33**	Hoàn tất
Cell 6	Full Model (`HPE + SCM + Bound`)	`base` / FUNSD	**91.58 ± 0.16**	Hoàn tất
Cell 7	Full Model (`HPE + SCM + Bound`)	`base` / CORD	**96.91 ± 0.21**	Hoàn tất
Cell 8	Nghiên cứu cắt giảm: w/o Boundary Loss	`base` / FUNSD	**91.62 ± 0.19**	Hoàn tất
Cell 9	Nghiên cứu cắt giảm: w/o Boundary Loss	`base` / CORD	**97.06 ± 0.18**	Hoàn tất
Cell 10	Nghiên cứu cắt giảm: w/o Token-Segment SCM	`base` / FUNSD	**90.36 ± 0.30**	Hoàn tất
Cell 11	Nghiên cứu cắt giảm: w/o Token-Segment SCM	`base` / CORD	**96.59 ± 0.57**	Hoàn tất
Cell 12	Nghiên cứu cắt giảm: w/o HPE	`base` / FUNSD	**91.33 ± 0.27**	Hoàn tất
Cell 13	Nghiên cứu cắt giảm: w/o HPE	`base` / CORD	**97.10 ± 0.15**	Hoàn tất
Cell 14	Baseline (LayoutLMv3)	`large` / FUNSD	**91.24 ± 0.61**	Hoàn tất
Cell 15	Baseline (LayoutLMv3)	`large` / CORD	**97.15 ± 0.17**	Hoàn tất
Cell 16	Full Model (`HPE + SCM + Bound`)	`large` / FUNSD	**92.45 ± 0.26**	Hoàn tất
Cell 17	Full Model (`HPE + SCM + Bound`)	`large` / CORD	**97.35 ± 0.04**	Hoàn tất
Cell 18	Nghiên cứu cắt giảm: w/o Boundary Loss	`large` / FUNSD	**92.15 ± 0.24**	Hoàn tất
Cell 19	Nghiên cứu cắt giảm: w/o Boundary Loss	`large` / CORD	**97.01 ± 0.42**	Hoàn tất
Cell 20	Nghiên cứu cắt giảm: w/o Token-Segment SCM	`large` / FUNSD	**91.01 ± 0.23**	Hoàn tất

Bảng 4.6: Kết quả nghiên cứu cắt giảm thành phần trên biến thể `LayoutLMv3-base`.

Thành phần kích hoạt			**Chỉ số FUNSD (Mean ± Std %)**		
HPE	**SCM**	**Boundary**	**Precision**	**Recall**	**F1**
			89.32 ± 1.31	90.53 ± 0.48	89.92 ± 0.85
✓		✓	89.54 ± 0.53	91.18 ± 0.41	90.36 ± 0.30
	✓	✓	91.42 ± 0.33	91.25 ± 0.33	91.33 ± 0.27
✓	✓		91.72 ± 0.26	91.52 ± 0.15	91.62 ± 0.19
✓	✓	✓	$\mathbf{91.82 \pm 0.05}$	$\mathbf{91.33 \pm 0.28}$	$\mathbf{91.58 \pm 0.16}$

Bảng 4.7: Phân tích chi tiết các nhóm lỗi mức thực thể trên tập kiểm thử FUNSD (1,998 thực thể chuẩn).

Loại kết quả / Nhóm lỗi mức thực thể	**LayoutLMv3$_{\mathbf{BASE}}$**	**Mô hình đề xuất**
Dự đoán khớp hoàn toàn (Khớp hoàn toàn ↑)	1806	**1830** (+24)
Lỗi sai loại thực thể (Sai loại ↓)	**89**	93
Lỗi sai ranh giới (Sai ranh giới: ngắn hơn / dài hơn ↓)	23 (19 / 4)	**4 (4 / 0)** (−82.6%)
Lỗi hỗn hợp (Lỗi hỗn hợp ↓)	1	**0**
Thực thể bị bỏ sót (Bỏ sót thực thể ↓)	79	**71** (−8)
Thực thể dự đoán thừa (Dự đoán thừa ↓)	72	**59** (−13)

Số liệu trong Bảng 4.7 khẳng định giả thuyết trọng tâm của khóa luận: phần lớn sự gia tăng số lượng thực thể khớp chính xác (+24 thực thể) đến từ việc **triệt tiêu tới** 82.6% **lỗi sai ranh giới** (giảm từ 23 lỗi xuống chỉ còn 4 lỗi, đặc biệt lỗi dự đoán bị cắt cụt giảm từ 19 xuống 4 và lỗi tràn ranh giới giảm về 0), đồng thời giảm cả số thực thể bị bỏ sót (79 → 71) và dự đoán thừa (72 → 59).

Bảng 4.8: Phân tích định tính các dạng lỗi của mô hình cơ sở và cơ chế khắc phục của mô hình đề xuất.

Dạng lỗi	**Hành vi của Baseline LayoutLMv3**	**Cải tiến bởi Mô hình đề xuất**	**Mô-đun phụ trách**
1. Phân mảnh thực thể	Các thực thể dài bị gãy đôi giữa dòng hoặc đổi nhãn đột ngột.	Gộp trung bình phân đoạn và $\mathcal{L}_{\text{bound}}$ ép đồng nhất biểu diễn token trong cùng phân đoạn.	Mô-đun SCM + $\mathcal{L}_{\text{bound}}$
2. Nhập nhằng ranh giới	Hộp phân đoạn dùng chung thiếu tín hiệu biên, sinh nhãn `B-` thừa.	Bộ chỉ số f_i bổ sung véc-tơ $\mathbf{e}_{\text{first}}$ đánh dấu vị trí bắt đầu phân đoạn.	`is_first_token_embedding` + ReZero α
3. Nhầm lẫn không gian	Các ô khóa và giá trị xếp chồng theo trục dọc bị nhầm với tiêu đề.	Phân bổ $d_y > d_x$ kết hợp phép chiếu phi tuyến giúp phân tách rõ ràng ranh giới dòng.	Mã hóa 2D phân cấp (HPE)

Về mặt chi phí tính toán, các thuật toán gom cụm dòng, khối, cột của HPE được thực thi một lần duy nhất trên CPU trong bước tiền xử lý dữ liệu. Trong quá trình lan truyền tiến, các mô-đun mở rộng chỉ bổ sung thêm 5.14M tham số ở quy mô `base` (tương đương 4.1% so với 125M tham số của xương sống) và 9.08M tham số ở quy mô `large` (tương đương 2.55% so với 356M tham số của xương sống), hoàn toàn giữ nguyên tốc độ suy luận thời gian thực.

Kết luận

Tài liệu tham khảo

[1] Lei Cui, Yiheng Xu, Tengchao Lv **and** Furu Wei. "Document AI: Benchmarks, Models and Applications". **in***arXiv preprint arXiv:2111.08609*: (2021).

[2] Yupan Huang, Tengchao Lv, Lei Cui, Yutong Lu **and** Furu Wei. "LayoutLMv3: Pre-training for Document AI with Unified Text and Image Masking". **in***Proceedings of the 30th ACM International Conference on Multimedia*: 2022, **pages** 4083–4091.

[3] Yiheng Xu, Minghao Li, Lei Cui, Shaohan Huang, Furu Wei **and** Ming Zhou. "LayoutLM: Pre-training of Text and Layout for Document Image Understanding". **in***Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*: 2020, **pages** 1192–1200.

[4] Yang Xu, Yiheng Xu, Tengchao Lv, Lei Cui, Furu Wei, Guoxin Wang, Yijuan Lu, Dinei Florencio, Cha Zhang, Wanxiang Che, Min Zhang **and** Lidong Zhou. "LayoutLMv2: Multi-modal Pre-training for Visually-rich Document Understanding". **in***Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*: 2021, **pages** 2579–2591.

[5] Guillaume Jaume, Hazim Kemal Ekenel **and** Jean-Philippe Thiran. "FUNSD: A Dataset for Form Understanding in Noisy Scanned Documents". **in***2019 International Conference on Document Analysis and Recognition Workshops (ICDARW)*: **volume** 2. IEEE. 2019, **pages** 1–6.

[6] Seunghyun Park, Seung Shin, Bado Lee, Junyeop Lee, Jaeheung Surh, Minjoon Seo **and** Hwalsuk Lee. "CORD: A Consolidated Receipt Dataset for Post-OCR Parsing". **in***Workshop on Document Intelligence at NeurIPS 2019*: 2019.

[7] Quynh-Trang Pham Thi, Van-Truong Le, Thanh-Huyen Pham, Thanh-Nga Hoang Thi **and** Duc-Trong Le. "DAKTA: Directional Kolmogorov-Arnold Classifier for Task Arithmetic in Continual Learning". **in***Proceedings of the 14th International Symposium on Information and Communication Technology (SOICT)*: Springer, 2025, **pages** 1–8.

[8] Jacob Devlin, Ming-Wei Chang, Kenton Lee **and** Kristina Toutanova. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". **in***Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*: 2019, **pages** 4171–4186.

[9] Srikar Appalaraju, Bhavan Jasani, Bhargava Urala Kota, Yusheng Xie **and** R. Manmatha. "DocFormer: End-to-End Transformer for Document Understanding". **in***Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*: 2021, **pages** 993–1003.

[10] Chenliang Li, Bin Bi, Ming Yan, Wei Wang, Songfang Huang, Fei Huang **and** Luo Luo. "StructuralLM: Structural Pre-training for Form Understanding". **in***Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL)*: 2021, **pages** 6309–6318.

[11] Teakgyu Hong, Donghyun Kim, Mingi Ji, Wonseok Hwang, Daehyun Nam **and** Sungrae Park. "BROS: A Spatial Encoding Framework for Document Image Understanding". **in***Advances in Neural Information Processing Systems (NeurIPS)*: **volume** 35. 2022, **pages** 18485–18497.

[12] Jiapeng Wang, Lianwen Jin **and** Kai Ding. "LiLT: A Simple Yet Effective Language-Independent Layout Transformer for Structured Document Understanding". **in***Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)*: 2022, **pages** 7747–7757.

[13] Chuwei Luo, Changxu Cheng, Qi Zheng **and** Cong Yao. "GeoLayoutLM: Geometric Pre-training for Visual Information Extraction". **in***Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*: 2023, **pages** 7092–7101.

[14] Qiwei Li, Zuchao Li, Xiantao Cai, Bo Du **and** Hai Zhao. "Enhancing Visually-Rich Document Understanding via Layout Structure Modeling".

in*Proceedings of the 31st ACM International Conference on Multimedia*: 2023, **pages** 4513–4523.

[15] Chuwei Luo, Yufan Shen, Zhaoqing Zhu, Qi Zheng, Zhi Yu **and** Cong Yao. "LayoutLLM: Layout Instruction Tuning with Large Language Models for Document Understanding". **in***Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*: 2024, **pages** 15630–15640.

[16] Dongsheng Wang, Natraj Raman, Mathieu Sibue, Zhiqiang Ma, Petr Babkin, Simerjot Kaur, Yulong Pei, Armineh Nourbakhsh **and** Xiaomo Liu. "DocLLM: A Layout-Aware Generative Language Model for Multimodal Document Understanding". **in***Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*: 2024, **pages** 8529–8548.

[17] Ming Ding, Zhuoyi Yang, Wenyi Hong, Wendi Zheng, Chang Zhou, Da Yin, Junyang Lin, Xu Zou, Zhou Shao, Hongxia Yang **and** Jie Tang. "CogView: Mastering Text-to-Image Generation via Transformers". **in***Advances in Neural Information Processing Systems (NeurIPS)*: **volume** 34. 2021, **pages** 19822–19835.

[18] Wonjae Kim, Bokyung Son **and** Ildoo Kim. "ViLT: Vision-and-Language Transformer Without convolutions or region supervision". **in***Proceedings of the 38th International Conference on Machine Learning (ICML)*: 2021, **pages** 5583–5594.

[19] Junlong Li, Yiheng Xu, Tengchao Lv, Lei Cui, Cha Zhang **and** Furu Wei. "DiT: Self-supervised Pre-training for Document Image Transformer". **in***Proceedings of the 30th ACM International Conference on Multimedia*: 2022, **pages** 3530–3539.

[20] Yi Tu, Ya Guo, Huan Chen **and** Jintao Tang. "LayoutMask: Enhance Text-Layout Interaction in Multi-modal Pre-training for Document Understanding". **in***Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*: 2023, **pages** 15200–15212.

[21] Jiuxiang Gu, Jason Kuen, Vlad I. Morariu, Handong Zhao, Rajiv Jain, Nikolaos Barmpalios, Ani Nenkova **and** Tong Sun. "UniDoc: Unified Pretraining Framework for Document Understanding". **in***Advances in Neural Information Processing Systems (NeurIPS)*: **volume** 34. 2021, **pages** 39–50.

[22] Chen-Yu Lee, Chun-Liang Li, Timothy Dozat, Vincent Perot, Guolong Su, Nan Hua, Joshua Ainslie, Renshen Wang, Yasuhisa Fujii **and** Tomas Pfister. "FormNet: Structural Encoding beyond Sequential Modeling in Form Document Information Extraction". **in***Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)*: 2022, **pages** 529–543.

[23] Pengfei Wang, Zhiyao Li, Jun Zhang **and** Jianshu Liu. "USTC-iFLYTEK at DocILE 2023: Multimodal Graph Attention Networks for Document Information Localization and Extraction". **in***CEUR Workshop Proceedings (CLEF 2023 Working Notes)*: **volume** 3497. 2023, **pages** 520–531.

[24] Ting Xie, Jun He **and** Yan Song. "ROAP: A Reading-Order and Attention-Prior Pipeline for Optimizing Layout Transformers in Key Information Extraction". **in***arXiv preprint arXiv:2601.05470*: (2026).

[25] Chen Zhang, Wei Chen, Lin Shen, Xiaolong Zhang **and** Hao Liu. "AET-Net: Multi-modal Alignment Enhancement for Document Understanding". **in***Proceedings of the AAAI Conference on Artificial Intelligence*: 2023, **pages** 3245–3253.

[26] Hoang-Minh Nguyen, Thi-Mai Tran **and** Quoc-Anh Vo. "OTCR: Optimal Transport Cross-modal Routing for Multimodal Document Information Extraction". **in***Proceedings of the MAGMaR Workshop at ACL 2026*: 2026, **pages** 78–88.

[27] Jialin Zhao, Kuan Wang, Shuo Li **and** Zihan Liu. "DocExtractNet: Robust Document Information Extraction with Multi-modal Feature Enhancement and Precision Hints". **in***Information Processing & Management*: 61.4 (2024), **page** 103721.

[28] Geewook Kim, Teakgyu Hong, Moonbin Yim, Ji-Hwan Nam, Jinyoung Park, Jinyeong Yim, Wonseok Hwang, Sangdoo Lee **and** Seunghyun Park. "OCR-free Document Understanding Transformer". **in***Proceedings of the European Conference on Computer Vision (ECCV)*: 2022, **pages** 498–517.

[29] Tian Zheng, Haofeng Liu, Siyuan Wang **and** Jun Zhao. "LayTextLLM: Spatial Layout Projector for Large Language Models in Document Understanding". **in***arXiv preprint arXiv:2407.01976*: (2024).

[30] Qi Sun, Yali Deng, Kang Zhou **and** Mo Yu. "DocLayLLM: Integrating LayoutLMv3 Visual Embeddings into Large Language Models for Document AI". **in***arXiv preprint arXiv:2408.15045*: (2024).

[31] Guozheng Lin, Yue Wu, Wei Cheng **and** Liang He. "Structure-Aware In-context Learning for Key Information Extraction". **in***arXiv preprint arXiv:2412.17092*: (2024).

[32] Zhen Tang, Zhi Chen, Dayuan Wu **and** Jun Feng. "GENKIE: Generative Key Information Extraction with OCR Self-Correction". **in***arXiv preprint arXiv:2310.16131*: (2023).

[33] Long Chen, Meng Zhang, Feilong Wu **and** Yihang Gao. "P2Net: Parallel Prediction Network with Information Isolation for Visually-Rich Document Understanding". **in***Findings of the Association for Computational Linguistics: ACL 2025*: 2025, **pages** 5520–5532.

[34] Rui Shao, Yuxin Sun, Chen Ding **and** Bowen Zhou. "PM3-KIE: Multi-model Probabilistic Reasoning for Key Information Extraction". **in***Findings of the Association for Computational Linguistics: ACL 2025*: 2025, **pages** 10750–10762.

[35] Quynh-Trang Pham Thi, Anh-Cuong Pham, Ngoc-Huyen Ngo **and** Duc-Trong Le. "Memory-Based Method using Prototype Augmentation for Continual Relation Extraction". **in***2022 RIVF International Conference on Computing and Communication Technologies (RIVF)*: IEEE. 2022, **pages** 1–6.

[36] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer **and** Veselin Stoyanov. "RoBERTa: A Robustly Optimized BERT Pretraining Approach". **in***arXiv preprint arXiv:1907.11692*: (2019).

[37] Thomas Bachlechner, Bodhisattwa Prasad Majumder, Henry Mao, Garrison Cottrell **and** Julian McAuley. "ReZero is All You Need: Fast Convergence at Large Depth". **in***Proceedings of the Thirty-Seventh Conference on Uncertainty in Artificial Intelligence (UAI)*: 2021, **pages** 1352–1361.